大/小/微模型赋能先进制造：实践与思考

Large/Small/Micro AI Models for Manufacturing (AI4M): Applications and Insights

宋学官

大连理工大学 机械工程学院



一、AI4M的背景意义

二、AI4M的基础知识

三、AI4M的研究进展

四、AI4M的案例展示

五、AI4M的瓶颈所在

六、AI4M的科学问题

七、AI4M的发展方向

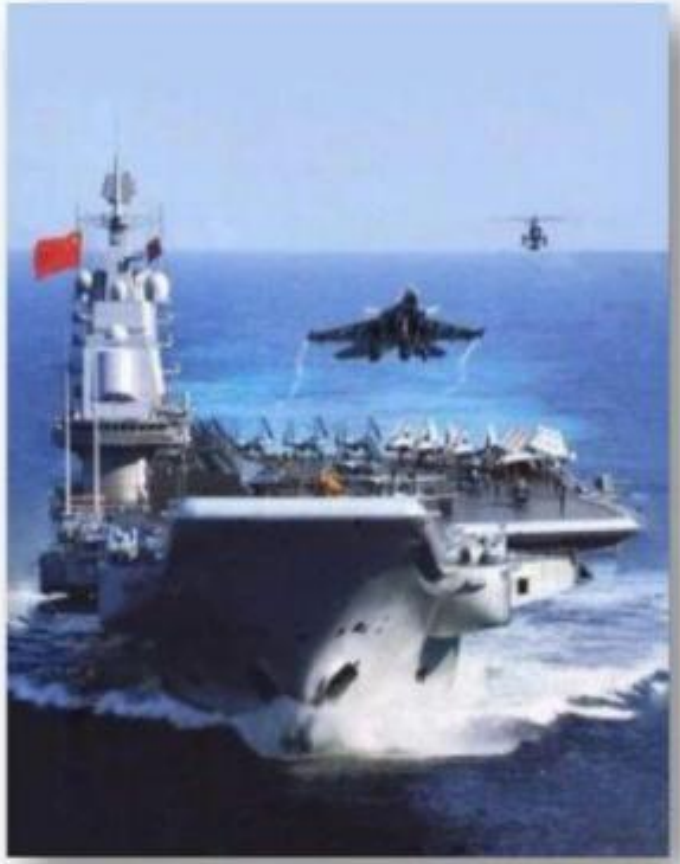
八、思考与总结



一、AI4M的背景意义
二、AI4M的基础知识
三、AI4M的研究进展
四、AI4M的案例展示
五、AI4M的瓶颈所在
六、AI4M的科学问题
七、AI4M的发展方向
八、思考与总结

AI4M的背景意义

- **先进制造**是指采用高新技术和先进设备来改善制造业过程和生产效率的统称，是衡量一个国家科技发展水平的重要标志，关乎国民经济发展和国防安全建设。








AI4M的背景意义

- 《中国制造2025》：加快推进制造业转型升级，**到2035年整体达到世界制造强国中等水平**
- 2022年10月，美国发布《国家先进制造业战略》，**先进制造业是美国经济和国家安全引擎**



AI4M的背景意义

“AI4M”已成为工业4.0的核心技术之一，世界主要工业强国的重点发展布局方向

年份	国家	重大计划或布局名称	目标
2023	美国	《美国国家人工智能研究和发展战略计划》	明确把AI作为国家优先事项，持续推动通用AI在包括智能设计在内的多个关键领域发展。
2018	德国	《联邦政府人工智能战略要点》	形成“人工智能德国制造”产业品牌，积极推动AI知识与技术向中小企业转移，强调通过智能设计提升创新活力。
2021	法国	《国家人工智能第二阶段发展战略（2021-2025年）》	将“推动法国成为嵌入式AI和可信AI领域领导者”作为三大目标之一。通过设立跨学科研究中心，统筹推进智能设计与智能制造发展。
2020	日本	《制造业基础技术的振兴政策》	强调数字化、智能化转型是“日本制造”的关键，将AI技术作为推进产品设计制造环节应用的核心。
2021	中国	《“十四五”智能制造发展规划》	将设计仿真、混合建模、多目标协同优化等作为设计领域的聚焦重点，将AI、大数据等在工业领域内的适用性技术作为攻关核心之一。

AI4M的背景意义

□ 人工智能(AI)：科学研究的第四范式，正深刻重塑先进制造全生命周期技术体系

10~20年

第一范式: 经验科学



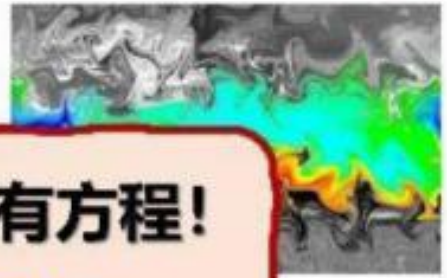
自然观察、经验总结

5~15年

第二范式: 理论科学

天~年

第三范式: 计算科学



值仿真

天~月

第四范式: 大数据科学



数据挖掘、机器学习

不可能“算得动”所有方程!

复杂工程问题“算不快”！

1600 1950 2000



一、AI4M的背景意义

二、AI4M的基础知识

三、AI4M的研究进展

四、AI4M的案例展示

五、AI4M的瓶颈所在

六、AI4M的科学问题

七、AI4M的发展方向

八、思考与总结

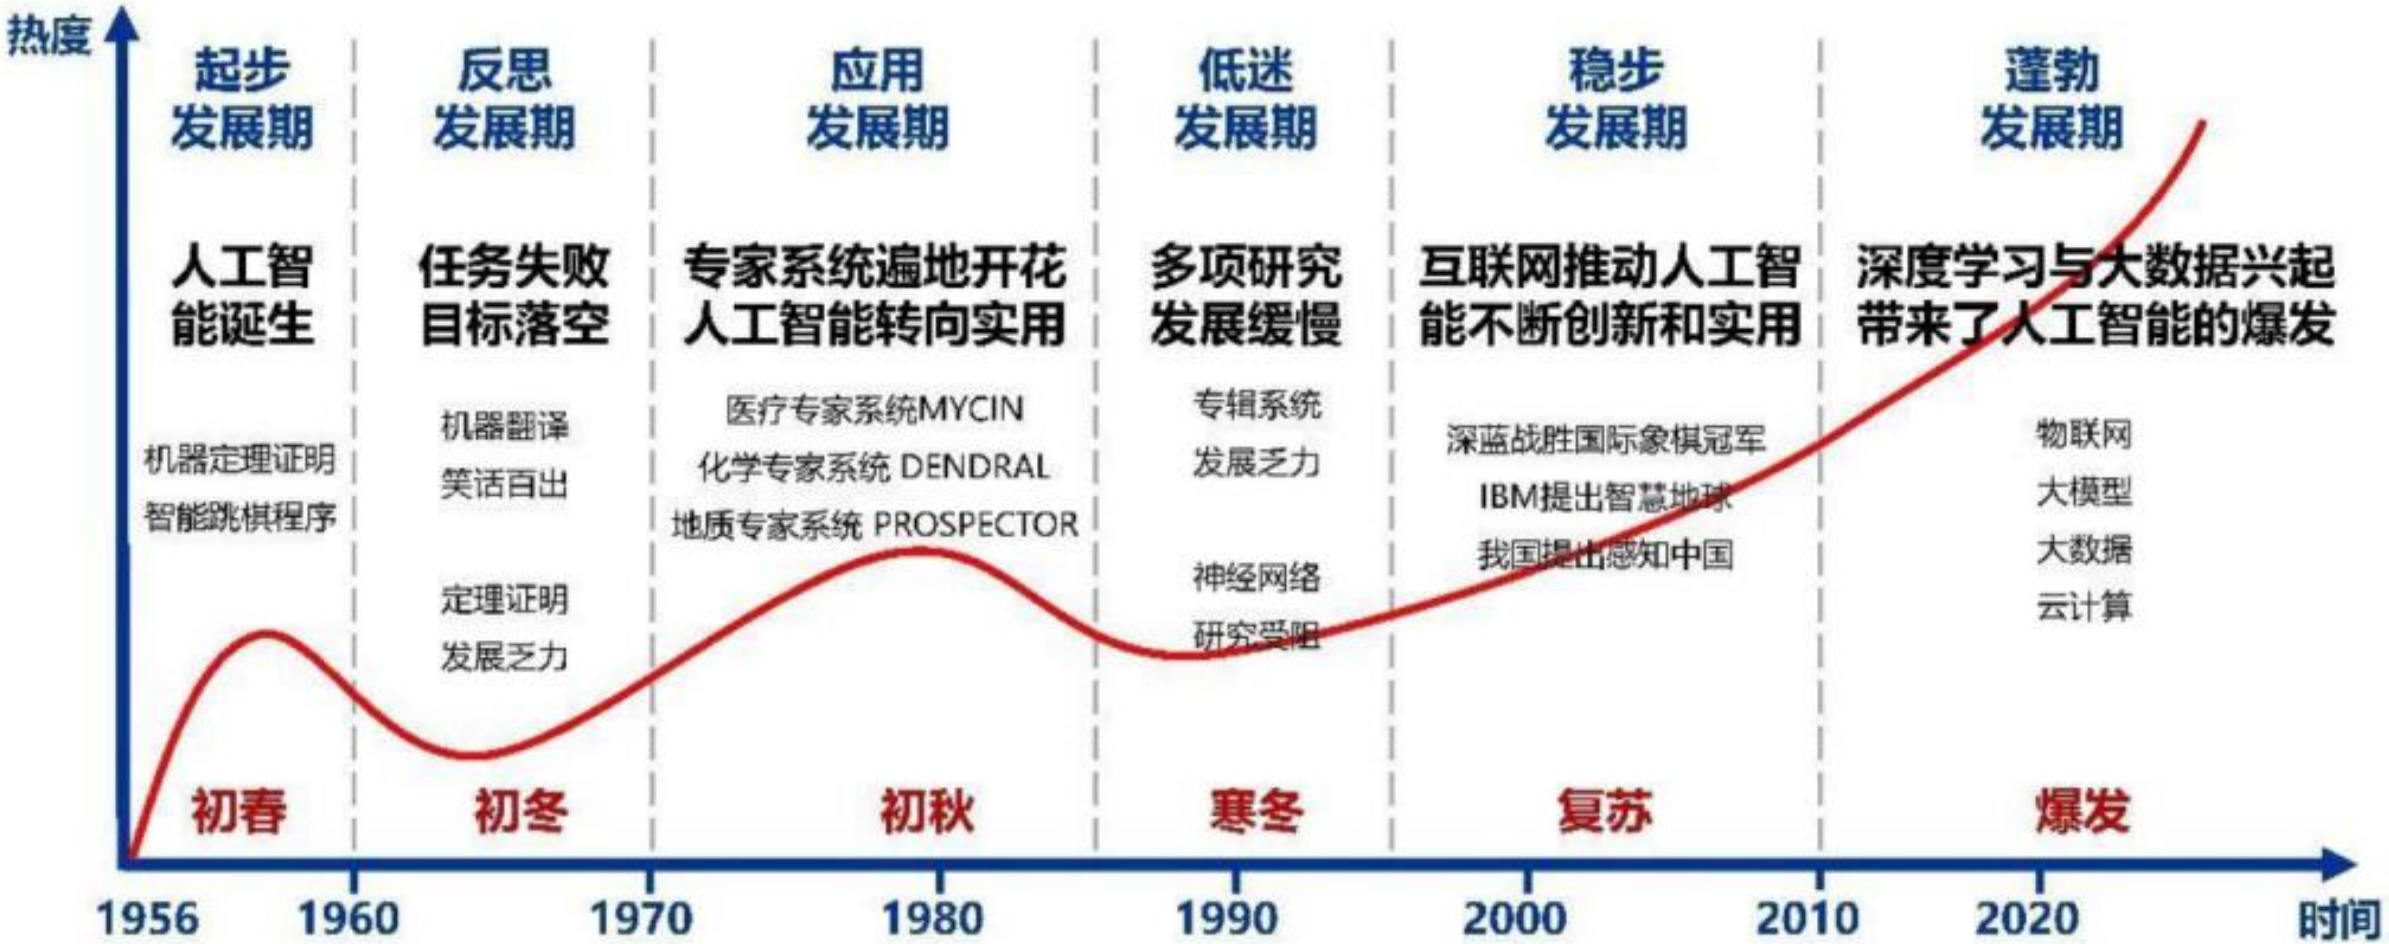
AI的发展历程

□ AI经过数十年发展才实现规模应用，在制造业的落地始终伴随着传感器和物联网技术的迭代升级。



AI的发展历程

□ 人工智能经历三次热潮与两次寒冬，技术在挫折中不断演进，当前正迈向以大模型为核心的新阶段。

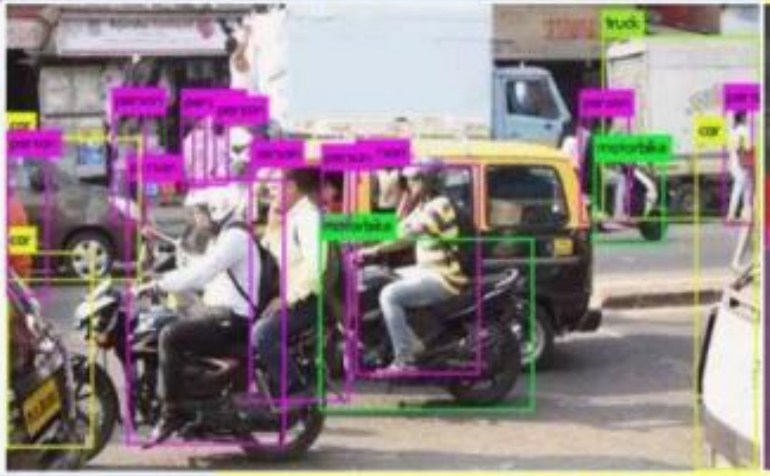


AI的不同分类方式

人脸检测识别



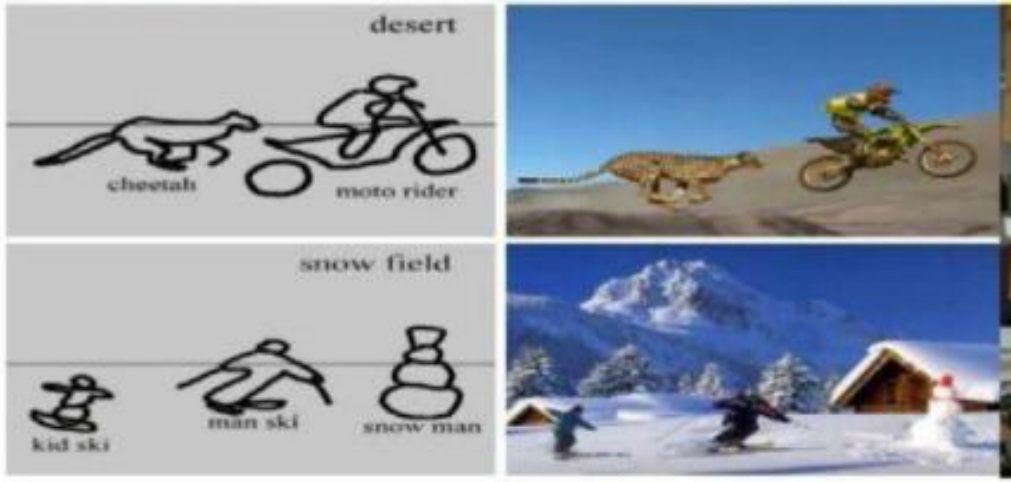
目标检测



图像分割



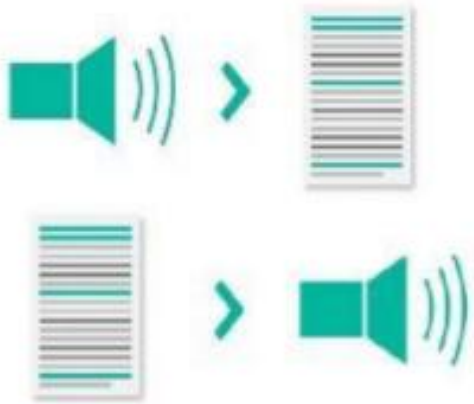
图像生成



音乐合成



文本声音互转



AI的不同分类方式

语言描述

Describes without errors

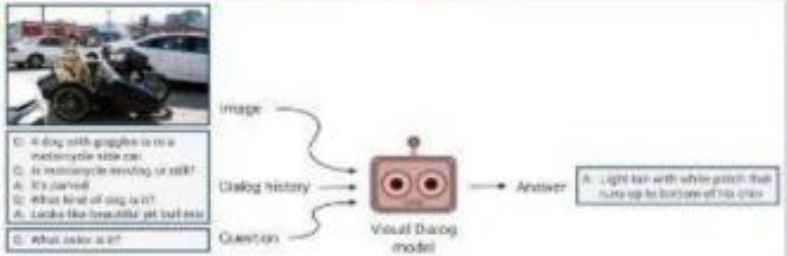


A person riding a motorcycle on a dirt road.

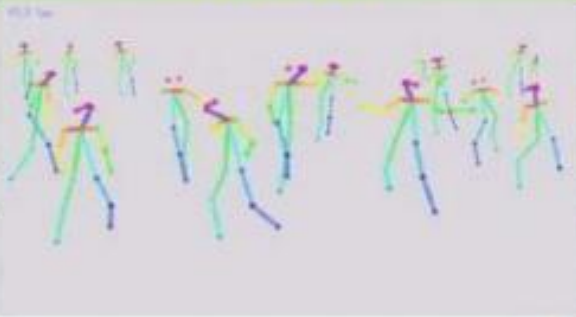


A group of young people playing a game of frisbee.

人机对话



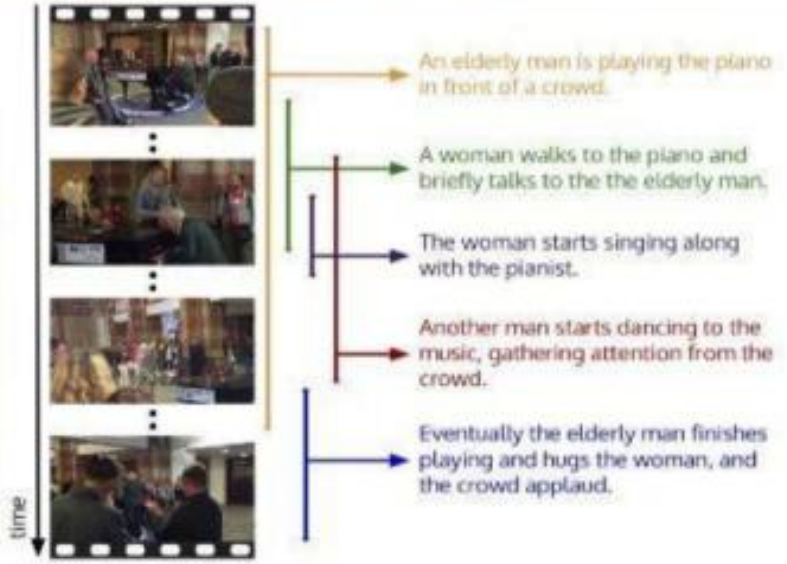
姿态估计



视频生成



视频解析



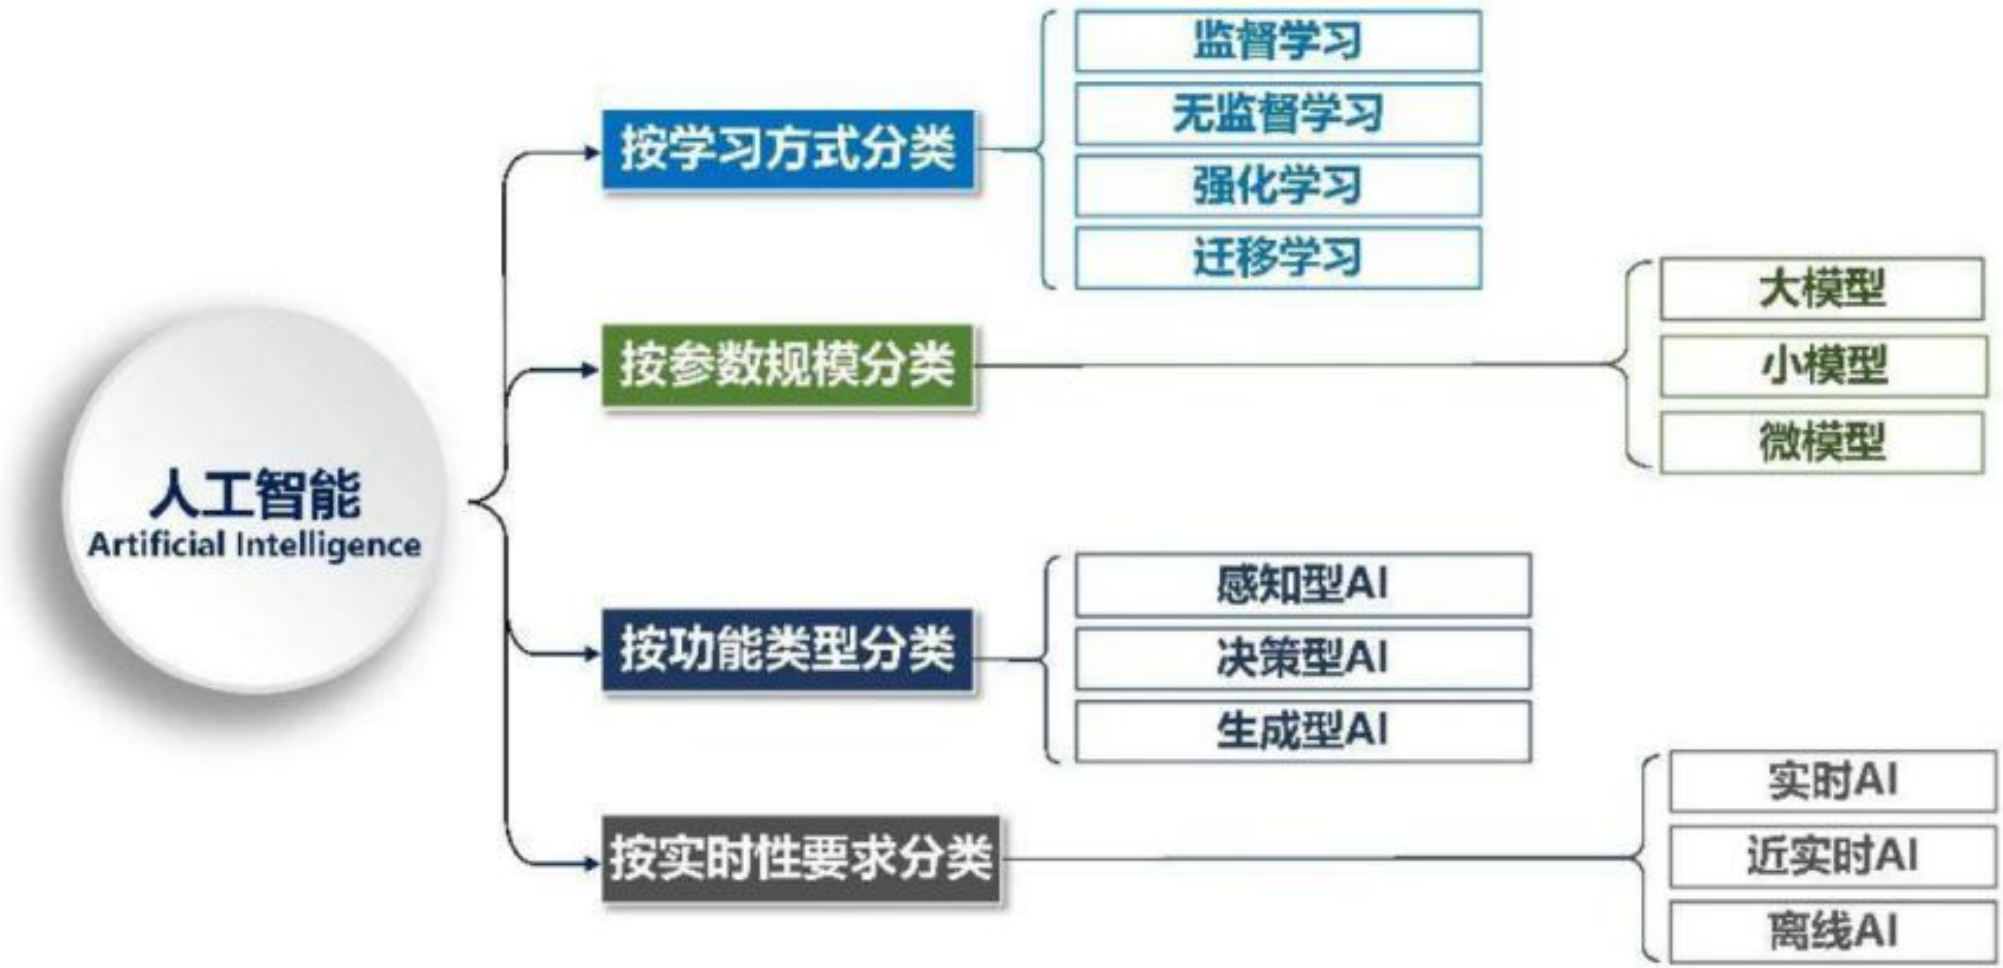
内容创作

deepseek

ChatGPT

AI的不同分类方式

□ AI可以根据学习方式、参数规模、功能类型和实时性要求等不同维度进行分类



AI的不同分类方式

□ AI可以根据模型结构复杂度和智能实现方式的差异进行系统性划分。



AI≈建造智能机器

作为整体领域，包含所有模拟人类智能的技术

ML≈让机器自己学

人工智能的一个重要分支，无需手动编程，机器通过数据训练，总结规律，自动改进性能

DL≈用复杂模型学

机器学习的重要分支，使用多层神经网络处理复杂数据，自动提取高层次特征。“深度”即：在网络中使用多层

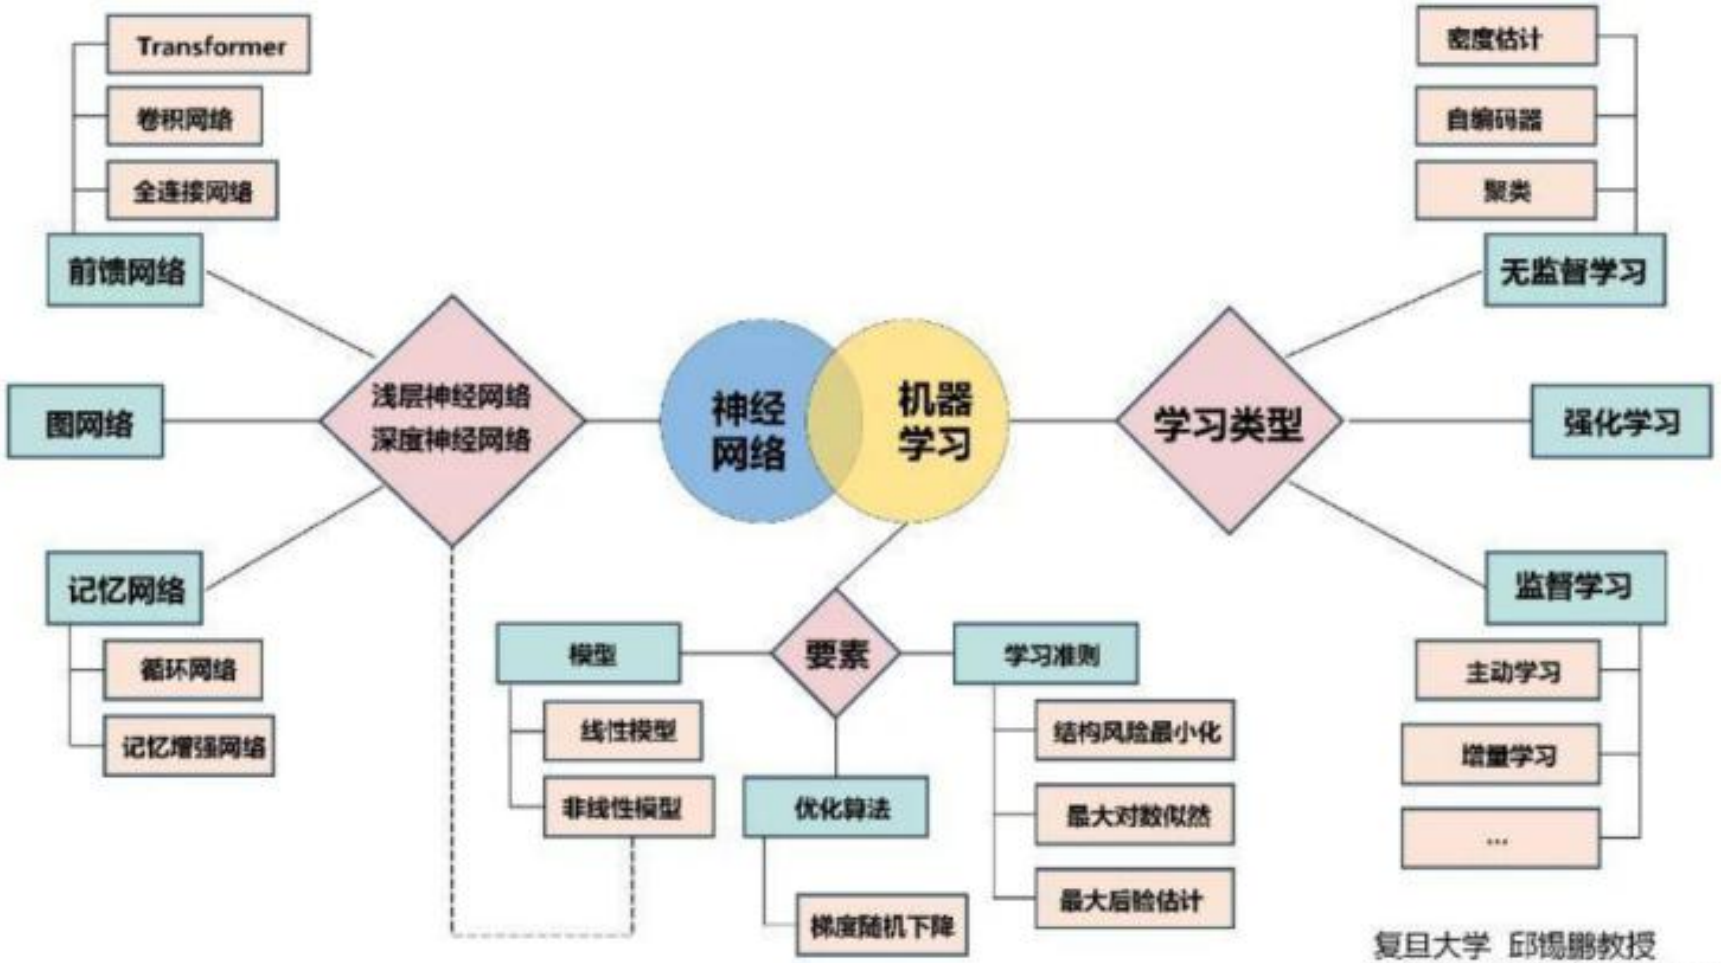
神经网络≈大脑的简化版计算单元

又称类神经网络/神经网络，是一种通过模拟人脑神经元的计算模型，由多层互联节点（神经元）组成

网址：https://zhuanlan.zhihu.com/p/1889735973048395146

AI的不同分类方式

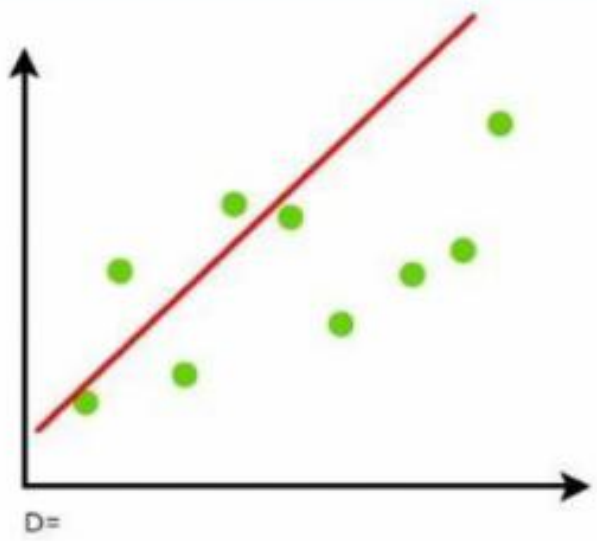
□ AI可以根据模型深度、学习策略和学习方式的不同进行系统性划分。



复旦大学 邱锡鹏教授
网址：https://cloud.tencent.cn/developer/article/1630825

最小二乘法

□ 一种简单有效的非线性拟合方法，适合低维、平滑、连续且样本适中的数据



问题描述：

给定一组数据点$(x_i, y_i), i = 1,2,...n$，我们希望找到一个m次多项式：

$$y(x) = w_0 + w_1 x + w_2 x^2 \dots + w_m x^m$$

使得误差平方和最小：$E = \sum_{i=1}^{n}(y_i - P(x_i))^2$

构建误差函数：

将多项式带入误差函数：

$$E(w_0, w_1, \dots, w_m) = \sum_{i=1}^{n}\left(y_i - \sum_{j=0}^{m} w_j x_i^j\right)^2$$

最小化误差：

为了最小化E，对每个系数w_k求偏导并令其为零：

$$\frac{\partial E}{\partial w_k} = 0, \quad k = 0,1,...m$$

计算偏导数：

$$\frac{\partial E}{\partial w_k} = -2\sum_{i=1}^{n}\left(y_i - \sum_{j=0}^{m} w_j x_i^j\right) x_i^k = 0$$

$$\sum_{i=1}^{n} y_i x_i^k = \sum_{j=0}^{m} w_j \sum_{i=1}^{n} x_i^{j+k}, \quad k = 0,1,...m$$

方程组：

将上述方程写成矩阵形式（正规方程组）：

$$\begin{cases} w_0 + w_1\sum x_i + w_2\sum x_i^2 + \cdots + w_m\sum x_i^m = \sum y_i \\ w_0\sum x_i + w_1\sum x_i^2 + w_2\sum x_i^3 \dots + w_m\sum x_i^{m+1} = \sum y_i x_i \\ \cdots \\ w_0\sum x_i^m + w_1\sum x_i^{m+1} + w_2\sum x_i^{m+2} \dots + w_m\sum x_i^{2m} = \sum y_i x_i^m \end{cases}$$

用矩阵表示：

$$X^T X w = X^T y$$

其中：

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 & \dots & x_1^m \\ 1 & x_2 & x_2^2 & \dots & x_2^m \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_n & x_n^2 & \dots & x_n^m \end{bmatrix}, \quad w = \begin{bmatrix} w_0 \\ w_1 \\ \dots \\ w_m \end{bmatrix}, \quad y = \begin{bmatrix} y_0 \\ y_1 \\ \dots \\ y_n \end{bmatrix}$$

求解系数：

解方程组：

$$w = (X^T X)^{-1} X^T y$$

关键点：

当$m < n - 1$时，通常有唯一解。

矩阵$X^T X$是对称且正定的（如果X列满秩）。

示例：

$$\begin{cases} w_0 n + w_1\sum x_i = \sum y_i \\ w_0\sum x_i + w_1\sum x_i^2 = \sum y_i x_i \end{cases}$$

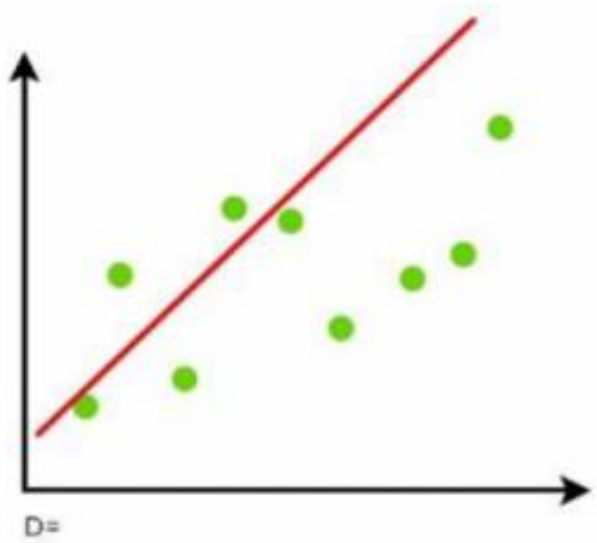
解得：

$$w_1 = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - (\sum x_i)^2}, \quad w_0 = \frac{\sum y_i - w_1\sum x_i}{n}$$

模型求解过程

多项式拟合

□ 一种简单有效的非线性拟合方法，适合低维、平滑、连续且样本适中的数据



D=

构造多项式特征：

模型： 二阶多项式模型

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_1x_2 + w_5x_2^2$$

数值案例： 输入x=[1, 2]^T，目标输出：y=10

初始参数：$w(0) = [0.1 \quad 0.1 \quad 0.1 \quad 0.1 \quad 0.1 \quad 0.1]^T$

学习率： $\eta = 0.01$

输入向量扩展为多项式特征向量：

$$\phi(x) = [1 \quad x_1 \quad x_2 \quad x_1^2 \quad x_1x_2 \quad x_2^2]^T = [1 \quad 1 \quad 2 \quad 1 \quad 2 \quad 4]^T$$

计算初始预测值：

$$\hat{y}^{(0)} = w^{(0)} \cdot \phi(x) = 0.1 \times 1 + 0.1 \times 1 + 0.1 \times 2 + 0.1 \times 1 + 0.1 \times 2 + 0.1 \times 4 = 1.1$$

损失函数：

计算损失函数，使用均方误差（MSE）：

$$L = (\hat{y} - y)^2 = (1.1 - 10)^2 = 79.21$$

反向传播：

梯度计算：

损失函数对权重的梯度：

$$\frac{\partial L}{\partial w_i} = (\hat{y} - y) \cdot \phi(i)$$

所以每一项的梯度：

$$\frac{\partial L}{\partial w} = (1.1 - 10) \cdot \begin{bmatrix}1\\1\\2\\1\\2\\4\end{bmatrix} = \begin{bmatrix}-8.9\\-8.9\\-17.8\\-8.9\\-17.8\\-35.6\end{bmatrix}$$

参数更新：

$$w^{(1)} \leftarrow w^{(0)} - \eta \cdot \nabla L$$

$$= \begin{bmatrix}1\\1\\1\\1\\1\\1\end{bmatrix} - 0.1 \cdot \begin{bmatrix}-8.9\\-8.9\\-17.8\\-8.9\\-17.8\\-35.6\end{bmatrix} = \begin{bmatrix}1.89\\1.89\\2.78\\1.89\\2.78\\4.56\end{bmatrix}$$

计算结果：

对上述过程重复100次，输出$\hat{y}$和MSE

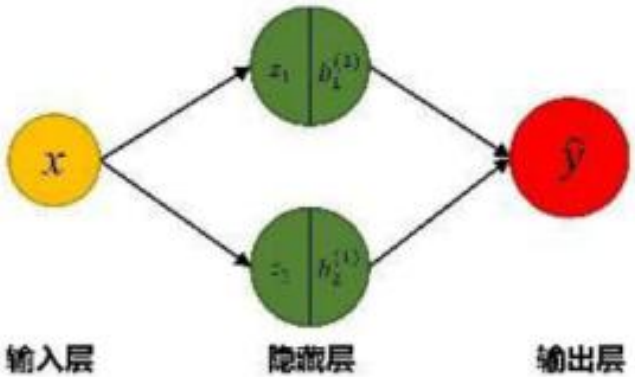
迭代次数	输出$\hat{y}$	MSE
1	1.10	79.21
2	3.48	42.50
...	...	...
100	≈1	$<10^5$

模型架构

模型求解过程

浅层神经网络

□ 模型结构简单，训练速度快，适用于小数据集，适合低维数据分类/回归。



模型架构： 输入层 （1个神经元）
隐藏层 （2个神经元，激活函数为ReLU）
输出层 （1个神经元，线性激活）

数值案例： 输入$x=[1,2]^T$，输出：$y=10$

初始参数： $W_1=\begin{bmatrix}0.1 & 0.2\\ 0.3 & 0.4\end{bmatrix}$，$b_1=[0.0 \quad 0.0]^T$

$W_2=[0.5 \quad 0.6]$，$b_2=0.0$

学习率： $\eta=0.01$

模型架构

前向传播：

隐藏层输入：$z_1=W_1x+b_1=\begin{bmatrix}0.1 & 0.2\\ 0.3 & 0.4\end{bmatrix}\begin{bmatrix}1\\2\end{bmatrix}=\begin{bmatrix}0.1+0.4\\0.3+0.8\end{bmatrix}=\begin{bmatrix}0.5\\1.1\end{bmatrix}$

隐藏层输出：$a_1=ReLU(z_1)=\begin{bmatrix}0.5\\1.1\end{bmatrix}$，激活函数$ReLU=\begin{cases}0, x<0\\ x, x\geq 0\end{cases}$

输出层输入：$z_2=W_2a_1=[0.5 \quad 0.6]\cdot\begin{bmatrix}0.5\\1.1\end{bmatrix}=0.25+0.66=0.91$

网络输入：$\hat{y}=z_2=0.91$

损失函数：

$L=\frac{1}{2}(y-\hat{y})^2=\frac{1}{2}(10-0.91)^2=\frac{1}{2}\cdot 82.81\approx 41.40$

反向传播：

输出层误差：$\delta_2=\hat{y}-y=0.91-10=-9.09$

输出层梯度：$\frac{\partial L}{\partial W_2}=\delta_2\cdot a_1^T=-9.09\cdot[0.5 \quad 1.1]=[-4.545 \quad -9.999]$

$\frac{\partial L}{\partial b_2}=\delta_2=-9.09$

隐藏层误差：

$\delta_1=(W_2^T\cdot\delta_2)\cdot ReLU'(z_1)\rightarrow\begin{bmatrix}0.5\\0.6\end{bmatrix}\cdot(-9.09)=\begin{bmatrix}-4.545\\-5.454\end{bmatrix}=\delta_1$

隐藏层梯度：$\frac{\partial L}{\partial W_1}=\delta_1\cdot x^T=\begin{bmatrix}-4.545\\-5.454\end{bmatrix}[1 \quad 2]=\begin{bmatrix}-4.545 & -9.090\\-5.454 & -10.908\end{bmatrix}$

$\frac{\partial L}{\partial b_1}=\delta_1=\begin{bmatrix}-4.545\\-5.454\end{bmatrix}$

参数更新：

$W_2\leftarrow W_2-\eta\frac{\partial L}{\partial W_2}$

$=[0.5 \quad 0.6]-0.01\cdot[-4.545 \quad -9.999]$

$=[0.5454 \quad -0.6999]$

$b_2\leftarrow b_2-\eta\cdot(-9.09)=0+0.0909=0.0909$

$W_1\leftarrow W_1-\eta\cdot\frac{\partial L}{\partial W_1}=\begin{bmatrix}0.14545 & 0.29090\\0.35454 & 0.50908\end{bmatrix}$

$b_1\leftarrow b_1-\eta\cdot\delta_1=\begin{bmatrix}0.04545\\0.05454\end{bmatrix}$

计算结果：

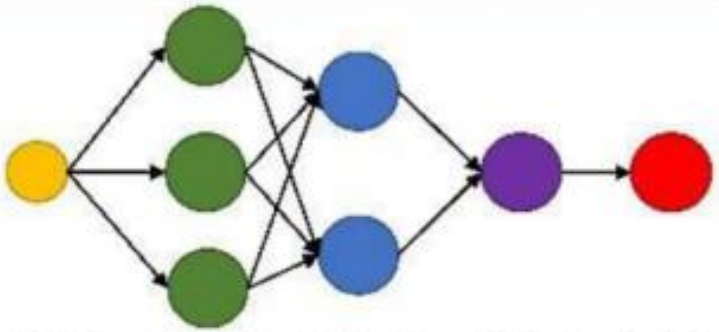
对上述过程重复100次，输出$\hat{y}$和MSE

迭代次数	输出$\hat{y}$	MSE
1	0.91	82.80
2	1.83	66.60
…	…	…
100	9.998	$<10^{-5}$

模型求解过程

深度学习神经网络（DNN）

□ 模型结构层次深，特征提取能力强，适用于**大规模数据集**，专为图像识别等数据设计。



模型架构： 输入层 （1个神经元）
隐藏层1（3个神经元，激活函数为ReLU）
隐藏层2（2个神经元，激活函数为ReLU）
隐藏层3（1个神经元，激活函数为ReLU）
输出层 （1个神经元，线性激活）

数值案例： 输入$x=[1,2]^T$，目标输出：$y=10$

初始参数：
$$W_1=\begin{bmatrix}0.1 & 0.2\\ 0.3 & 0.4\\ 0.5 & 0.6\end{bmatrix},\ b_1=[0\quad 0\quad 0]^T$$
$$W_2=\begin{bmatrix}0.1 & 0.2 & 0.3\\ 0.4 & 0.5 & 0.6\end{bmatrix},\ b_2=[0\quad 0]^T$$
$$W_3=[0.1\quad 0.2],\ b_3=0$$
$$W_4=[0.3],\ b_4=0$$

学习率： $\eta=0.01$

模型架构

前向传播：

隐藏层1输入：$z_1=W_1x+b_1=\begin{bmatrix}0.1 & 0.2\\ 0.3 & 0.4\\ 0.5 & 0.6\end{bmatrix}\begin{bmatrix}1\\2\end{bmatrix}+\begin{bmatrix}0\\0\\0\end{bmatrix}=\begin{bmatrix}0.5\\1.1\\1.7\end{bmatrix}$

隐藏层1输出：$a_1=ReLU(z_1)=\begin{bmatrix}0.5\\1.1\\1.7\end{bmatrix}$

隐藏层2输入：$z_2=W_2x+b_2=\begin{bmatrix}0.1 & 0.2 & 0.3\\ 0.4 & 0.5 & 0.6\end{bmatrix}\begin{bmatrix}0.5\\1.1\\1.7\end{bmatrix}+\begin{bmatrix}0\\0\end{bmatrix}=\begin{bmatrix}0.78\\1.77\end{bmatrix}$

隐藏层2输出：$a_2=ReLU(z_2)=\begin{bmatrix}0.78\\1.77\end{bmatrix}$

隐藏层3输入：$z_3=W_3x+b_3=[0.1\quad 0.2]\begin{bmatrix}0.78\\1.77\end{bmatrix}+0=0.432$

隐藏层3输出：$a_3=ReLU(z_3)=0.432$

输出层输入：$z_4=W_4a_3=0.3\times 0.432+0=0.1296$

网络输入：$\hat{y}=z_4=0.1296$

损失函数：

$$L=\frac{1}{2}(y-\hat{y})^2=\frac{1}{2}(10-0.1296)^2=\frac{1}{2}\times 9.8704^2\approx 48.71$$

反向传播：

输出层误差：$\delta_4=\frac{\partial L}{\partial z_4}=\hat{y}-y=0.1296-10=-9.8704$

隐藏层3误差：$\delta_3=(W_4\cdot\delta_4)\odot ReLU'(z_3)$
$=0.3\times(-9.8704)\times 1=-2.9611$

隐藏层2误差：$\delta_2=(W_3\cdot\delta_3)\odot ReLU'(z_2)$
$=\begin{bmatrix}0.1\\0.2\end{bmatrix}\times(-2.9611)\odot\begin{bmatrix}1\\1\end{bmatrix}$
$=\begin{bmatrix}-0.2961\\-0.5922\end{bmatrix}$

隐藏层1误差：$\delta_1=(W_2\cdot\delta_2)\odot ReLU'(z_1)$
$=\left(\begin{bmatrix}0.1 & 0.4\\ 0.2 & 0.5\\ 0.3 & 0.6\end{bmatrix}\begin{bmatrix}-0.2961\\-0.5922\end{bmatrix}\right)\odot ReLU'\left(\begin{bmatrix}0.5\\1.1\\1.7\end{bmatrix}\right)$
$=\begin{bmatrix}-0.26649\\-0.35532\\-0.44415\end{bmatrix}$

输出层梯度：$\frac{\partial L}{\partial W_4}=\delta_4\cdot a_3=0.432\times(-9.8704)$
$=-4.263$

$\frac{\partial L}{\partial b_4}=\delta_4=-9.8704$

隐藏层3梯度：$\frac{\partial L}{\partial W_3}=\delta_3\cdot a_2=-2.9611\times\begin{bmatrix}0.78\\1.77\end{bmatrix}$
$=\begin{bmatrix}-2.3096\\-5.2433\end{bmatrix}$

模型求解过程

深度学习神经网络（DNN）

□ 模型结构层次深，特征提取能力强，适用于大规模数据集，专为图像识别等数据设计。

$$\frac{\partial L}{\partial b_3} = \delta_3 = -2.9611$$

隐藏层2梯度：$\frac{\partial L}{\partial W_2} = a_1 \cdot \delta_2^T = \begin{bmatrix}0.5\\1.1\\1.7\end{bmatrix} \times [-0.2961 \quad -0.5922] = \begin{bmatrix}-0.1481 & -0.2961\\-0.3257 & -0.6514\\-0.5034 & -1.0067\end{bmatrix}$

$$\frac{\partial L}{\partial b_2} = \delta_2 = \begin{bmatrix}-0.2961\\-0.5922\end{bmatrix}$$

隐藏层1梯度：$\frac{\partial L}{\partial W_1} = x \cdot \delta_1^T = \begin{bmatrix}1\\2\end{bmatrix} \times [-0.26649 \quad -0.35532 \quad -0.44415]$

$$= \begin{bmatrix}-0.26649 & -0.35532 & -0.44415\\-0.53298 & -0.71064 & -0.88830\end{bmatrix}$$

$$\frac{\partial L}{\partial b_1} = \delta_1 = \begin{bmatrix}-0.26649\\-0.35532\\-0.44415\end{bmatrix}$$

参数更新：

$$W_l = W_l - \eta \cdot \frac{\partial L}{\partial W_l}$$

$$b_l = b_l - \eta \cdot \frac{\partial L}{\partial b_l}$$

输出层更新：$W_4 = 0.3 - 0.01 \times (-4.263) = 0.3426$

$b_4 = 0 - 0.01 \times (-9.8704) = 0.0987$

隐藏层3更新：$W_3 = \begin{bmatrix}0.1\\0.2\end{bmatrix} - 0.01 \times \begin{bmatrix}-2.3096\\-5.2433\end{bmatrix} = \begin{bmatrix}0.1231\\0.2524\end{bmatrix}$

$b_3 = 0 - 0.01 \times (-2.9611) = 0.0296$

隐藏层2更新：$W_2 = \begin{bmatrix}0.1 & 0.4\\0.2 & 0.5\\0.3 & 0.6\end{bmatrix} - 0.01 \times \begin{bmatrix}-0.1481 & -0.2961\\-0.3257 & -0.6514\\-0.5034 & -1.0067\end{bmatrix} = \begin{bmatrix}0.1015 & 0.4029\\0.2033 & 0.5065\\0.3050 & 0.6101\end{bmatrix}$

$$b_2 = \begin{bmatrix}0\\0\end{bmatrix} - 0.01 \times \begin{bmatrix}-0.2961\\-0.5922\end{bmatrix} = \begin{bmatrix}0.00296\\0.00592\end{bmatrix}$$

隐藏层1更新：$W_1 = \begin{bmatrix}0.1 & 0.3 & 0.5\\0.2 & 0.4 & 0.6\end{bmatrix} - 0.01 \times \begin{bmatrix}-0.26649 & -0.35532 & -0.44415\\-0.53298 & -0.71064 & -0.88830\end{bmatrix}$

$$= \begin{bmatrix}0.10266 & 0.30355 & 0.50444\\0.20533 & 0.40711 & 0.60888\end{bmatrix}$$

$$b_1 = \begin{bmatrix}0\\0\\0\end{bmatrix} - 0.01 \times \begin{bmatrix}-0.26649\\-0.35532\\-0.44415\end{bmatrix} = \begin{bmatrix}0.00266\\0.00355\\0.00444\end{bmatrix}$$

计算结果：

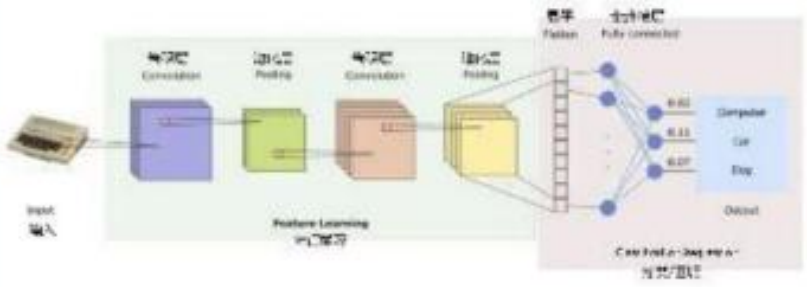
对上述过程重复100次，输出$\hat{y}$和MSE

迭代次数	输出$\hat{y}$	MSE
1	0.1296	96.84
2	0.3448	93.24
…	…	…
100	10.6241	0.3895

模型求解过程

卷积神经网络（CNN）

□ 模型通过局部连接和权值共享机制，能够高效提取图像局部特征，适用于机械制造中的视觉检测任务，如零件表面划痕检测、尺寸精度测量和装配完整性检查等。



模型架构： 输入层：

卷积层：1个3*3卷积核，步长1，输出大小3*3（ReLU激活函数）

池化层：2*2最大池化，步长2，输出1*1

全连接层：1个隐藏神经元，ReLU

输出层：1个神经元

数值案例： 输入$X=\begin{bmatrix}1&2&3&0&1\\0&1&2&3&1\\1&0&1&2&0\\2&1&0&1&3\\1&2&3&0&2\end{bmatrix}$，输出：y=10

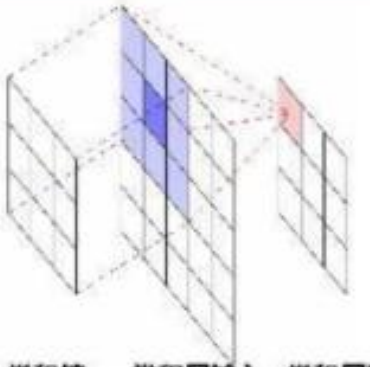
学习率： $\eta=0.01$

卷积层：

权重和偏置：

卷积核：$K=\begin{bmatrix}0.1&0.2&0.1\\0.0&0.1&0.2\\0.2&0.1&0.0\end{bmatrix}$

$b_2=0$



卷积核　卷积层输入　卷积层输出

前向传播：

以左上角3*3区域为例

对应元素乘积后求和：

$$Z_{0,0}=\sum_{m=0}^{2}\sum_{n=0}^{2}K_{m,n}\cdot K_{(i+m,j+n)}+b$$
$$=(1\times0.1+2\times0.2+3\times0.1)$$
$$+(0\times0.0+1\times0.1+2\times0.2)$$
$$+(1\times0.2+0\times0.1+1\times0.0)$$
$$=(0.1+0.4+0.3)+(0+0.1+0.4)+(0.2+0+0)$$
$$=1.5$$

以上述方式逐个计算区域与卷积核的乘积之和，

卷积层输出：

$$Z_{conv}=\begin{bmatrix}1.5&1.7&1.3\\1.1&1.5&1.2\\0.7&1.3&1.8\end{bmatrix}$$

激活函数（ReLU）：$A_{conv}=max(0,Z_{conv})=Z_{conv}$

池化层：

取前2*2区域：

$$pooling\ regin$$
$$=max\begin{Bmatrix}Z_{2i,2j}&Z_{2i,2j+1}\\Z_{2i+1,2j}&Z_{2i+1,2j+1}\end{Bmatrix}$$
$$=max\begin{bmatrix}1.5&\mathbf{1.7}\\1.1&1.5\end{bmatrix}$$
$$\rightarrow A_{pool}=1.7$$

全连接层（ReLU）：

权重：$W_{fc}=0.5$

偏置：$b_{fc}=0.5$

$$Z_{fc}=W_{fc}\cdot A_{pool}+b_{fc}=0.5\times1.7+0.5=1.35$$
$$A_{fc}=max(0,Z_{fc})=1.35$$

输出层：

权重：$W_{out}=0.3$

偏置：$b_{out}=0$

$$Z_{out}=W_{out}\cdot A_{fc}+b_{out}=0.3\times1.35+0=0.405$$
$$\hat{y}=Z_{out}=0.405$$

卷积神经网络（CNN）

□ 模型通过局部连接和权值共享机制，能够高效提取图像局部特征，适用于机械制造中的视觉检测任务，如零件表面划痕检测、尺寸精度测量和装配完整性检查等。

损失函数：

$L = (y - \hat{y})^2 = (10 - 0.405)^2 \approx 92.064$

反向传播：

输出层：$\frac{\partial L}{\partial \hat{y}} = 2(\hat{y} - y) = -19.19$

$$\frac{\partial L}{\partial W_{out}} = \frac{\partial L}{\partial \hat{y}} \cdot A_{fc} = -19.19 \times 0.85 = -16.3115$$

全连接层：$\frac{\partial L}{\partial z_{fc}} = \frac{\partial L}{\partial A_{fc}} \cdot W_{out} = -19.19 \times 0.3 = -5.757$

$$\frac{\partial L}{\partial W_{fc}} = -5.757 \cdot A_{pool} = -5.757 \times 1.7 = -9.7869$$

回传至池化层：$\frac{\partial L}{\partial A_{conv}[0,1]} = -5.757 \times 0.5 = -2.8785$

回传至卷积核：$\frac{\partial L}{\partial K} = -2.8785 \cdot \begin{bmatrix} 2 & 3 & 0 \\ 1 & 2 & 3 \\ 0 & 1 & 2 \end{bmatrix}$

$$= \begin{bmatrix} -5.757 & -8.6355 & 0 \\ -2.8785 & -5.757 & -8.6355 \\ 0 & -2.8785 & -5.757 \end{bmatrix}$$

参数更新：

$$W_{out} = W_{out} - \eta \cdot \frac{\partial L}{\partial W_{out}} \leftarrow 0.3 - 0.01 \times (-16.5665) = 0.465665$$

$$W_{fc} = W_{fc} - \eta \cdot \frac{\partial L}{\partial W_{fc}} \leftarrow 0.5 - 0.01 \times (-9.9399) = 0.599399$$

$$K_{new} = \begin{bmatrix} 0.1 & 0.2 & 0.1 \\ 0.0 & 0.1 & 0.2 \\ 0.2 & 0.1 & 0.0 \end{bmatrix} - 0.01 \cdot \begin{bmatrix} -5.757 & -8.6355 & 0 \\ -2.8785 & -5.757 & -8.6355 \\ 0 & -2.8785 & -5.757 \end{bmatrix}$$

$$= \begin{bmatrix} 0.15757 & 0.286355 & 0.1 \\ 0.028785 & 0.15757 & 0.286355 \\ 0.2 & 0.129785 & 0.05757 \end{bmatrix}$$

计算结果：

对上述过程重复100次，输出$\hat{y}$和MSE

迭代次数	输出$\hat{y}$	MSE
1	0.405	94.965
2	0.3448	93.24
...	...	...
100	9.547	0.103

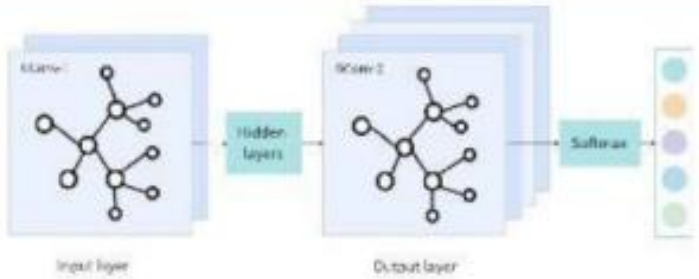
图神经网络（GNN）

- 图神经网络（Graph Neural Network）突破传统CNN对规则数据的限制，通过图结构直接建模机械系统的复杂物理关系，成为智能机械研究的新范式。



图神经网络（GNN）

□ 模型擅长处理拓扑关系数据，适用于机械系统故障传播分析等复杂系统分析。



模型架构： 输入为图$G=(V,E)$，共3个节点，每个节点输入为一个2维向量
一层图卷积层，一层全连接输出层

节点特征输入： $X=\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}1&2\\0&1\\3&1\end{bmatrix}$

输出： y=10

邻接矩阵： $A=\begin{bmatrix}0&1&0\\1&0&1\\0&1&0\end{bmatrix}$

GCN结构： $H=AXW_1+b_1$

初始参数： 图卷积权重$W_1=\begin{bmatrix}0.1&0.2\\0.3&0.4\end{bmatrix}$，
偏置$b_1=[0.0\quad 0.0]^T$
回归层权重$W_{fc}=[0.5\quad 0.6]$，偏置$b_{fc}=0$

学习率： $\eta=0.01$

模型架构

前向传播（以节点2为例）：

节点2的邻居是$\{v_1\quad v_3\}$，对应的特征是$\{x_1\quad x_3\}$，

计算邻接传播：$AX=\begin{bmatrix}0&1&0\\1&0&1\\0&1&0\end{bmatrix}\begin{bmatrix}1&2\\0&1\\3&1\end{bmatrix}=\begin{bmatrix}0&1\\4&3\\0&1\end{bmatrix}$

图卷积输出：$H=AXW_1+b_1=\begin{bmatrix}0&1\\4&3\\0&1\end{bmatrix}\begin{bmatrix}0.1&0.2\\0.3&0.4\end{bmatrix}=\begin{bmatrix}0.3&0.4\\1.3&2.0\\0.3&0.4\end{bmatrix}$

全图平均池化（取所有节点的平均）：

$$\bar{H}=\frac{1}{3}\sum_{i=1}^{3}H_i=\frac{1}{3}[0.3+1.3+0.3\quad 0.4+2.0+0.4]=[0.6333\quad 0.9333]$$

输出层：$\hat{y}=W_{fc}\cdot\bar{H}+b_{fc}=[0.5\quad 0.6]\cdot\begin{bmatrix}0.6333\\0.9333\end{bmatrix}=0.8767$

损失函数：

$L=(y-\hat{y})^2=(10-0.8767)^2=83.007$

反向传播：

输出层一阶导数：$\frac{\partial L}{\partial\hat{y}}=\hat{y}-y=0.8767-10=-9.1233$

输出层权重梯度：$\frac{\partial L}{\partial w_{fc}}=\frac{\partial L}{\partial\hat{y}}\cdot\frac{\partial\hat{y}}{\partial w_{fc}}=-9.1233\cdot\bar{H}$

$=-9.1233\cdot[0.6333\quad 0.9333]=[-5.7787\quad -8.5145]$

模型求解过程

图神经网络（GNN）

□ 模型擅长处理拓扑关系数据，适用于机械系统故障传播分析等复杂系统分析。

回归层偏置梯度：

$$\frac{\partial L}{\partial b_{fc}} = \frac{\partial L}{\partial \hat{y}} = -9.1233$$

更新回归层参数：

$$W_{fc} \leftarrow W_{fc} - \eta \cdot \frac{\partial L}{\partial W_{fc}}$$

$$= [0.5 \quad 0.6] - 0.01 \cdot [-5.7787 \quad -8.5145]$$

$$= [0.5806 \quad 0.7934]$$

$$b_{fc} \leftarrow b_{fc} - \eta \cdot \frac{\partial L}{\partial b_{fc}}$$

$$= 0 - 0.01 \times (-9.1233) = 0.0912$$

回归层输出：

$$\hat{y} = W_{fc} \cdot \bar{H} + b_{fc}$$

$$b_{fc} = 0$$

$$\rightarrow \frac{\partial L}{\partial \bar{H}} = \frac{\partial L}{\partial \hat{y}} \cdot W_{fc} = -9.1233 \times [0.5 \quad 0.6] = [-4.5617 \quad -5.4740]$$

平均池化是对3个节点取平均：

$$\frac{\partial L}{\partial H_i} = \frac{1}{3} \cdot \frac{\partial L}{\partial \bar{H}} = \frac{1}{3} \cdot [-4.5617 \quad -5.4740] = [-1.5206 \quad -1.8247]$$

参数更新：

令损失对图卷积权重W_1的梯度为：

$$\frac{\partial L}{\partial W_1} = (AX)^T \cdot \frac{\partial L}{\partial H} = \begin{bmatrix} 0 & 4 & 0 \\ 1 & 3 & 1 \end{bmatrix} \cdot \begin{bmatrix} -1.5206 & -1.8247 \\ -1.5206 & -1.8247 \\ -1.5206 & -1.8247 \end{bmatrix} = \begin{bmatrix} -6.0825 & -7.2988 \\ -6.0825 & -9.1235 \end{bmatrix}$$

更新图卷积权重

$$W_1 \leftarrow W_1 - \eta \cdot \frac{\partial L}{\partial W_1}$$

$$= \begin{bmatrix} 0.1 & 0.2 \\ 0.3 & 0.4 \end{bmatrix} + 0.01 \times \begin{bmatrix} 6.0825 & 7.2988 \\ 6.0825 & 9.1235 \end{bmatrix}$$

$$= \begin{bmatrix} 0.1608 & 0.2729 \\ 0.3608 & 0.4912 \end{bmatrix}$$

计算结果：

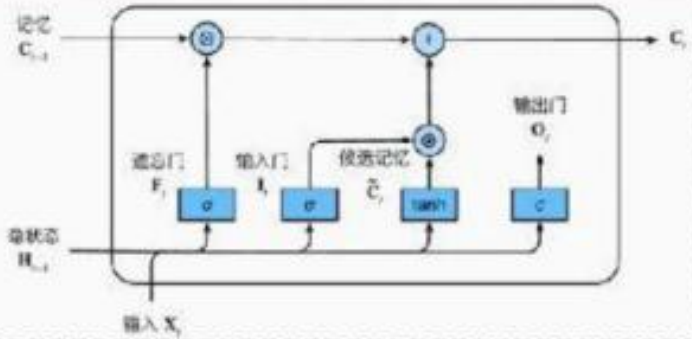
对上述过程重复100次，输出$\hat{y}$和MSE

迭代次数	输出$\hat{y}$	MSE
1	0.8767	83.007
2	2.5347	55.773
…	…	…
100	≈ 10.0	$<10^{-5}$

模型求解过程

长短期记忆网络(LSTM)

□ 模型擅长处理时序依赖，适用于信号分析、寿命预测等时间序列数据处理任务。



模型架构： 输入：2个神经元（向量$x_t \in R^2$）
隐状态维度：1（即$h_t \in R$）
仅1个LSTM单元（单时间步）
输出层：1个神经元，线性输出
激活函数：$sigmoid: \sigma(z) = \frac{1}{1+e^{-z}}$

$$sigmoid: \sigma(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

卷积层：1个3*3卷积核，步长1，
输出大小3*3（ReLU激活函数）
池化层：2*2最大池化，步长2，输出1*1
全连接层：1个隐藏神经元，ReLU
输出层：1个神经元

数值案例： 输入$x = \begin{bmatrix} 1.0 \\ 2.0 \end{bmatrix}$，目标输出：y=10

学习率： $\eta = 0.01$

初始参数：

遗忘门	W_f	[0.1 0.2]	U_f	[0.3]	b_f	0.1
输入门	W_i	[0.2 0.3]	U_i	[0.1]	b_i	0.1
候选状态	W_c	[0.1 0.2]	U_c	[0.0]	b_c	0.0
输出门	W_o	[0.2 0.1]	U_o	[0.2]	b_o	0.1
输出层	W_y	[0.5]	b_y	0		

前向传播：

遗忘门：$W_f x_t = 0.1 \times 1 + 0.2 \times 2 = 0.5$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$
$$= \sigma(0.5 + 0 + 0.1) = \sigma(0.6) \approx 0.645$$

输入门：$W_i x_t = 0.2 \times 1 + 0.3 \times 2 = 0.8$

$$U_i h_{t-1} = 0$$
$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$$
$$= \sigma(0.8 + 0 + 0.1) = \sigma(0.9) \approx 0.711$$

候选记忆：$W_c x_t = 0.1 \times 1 + 0.2 \times 2 = 0.5$

$$U_c h_{t-1} = 0$$
$$\tilde{C}_t = tanh(W_c x_t + U_c h_{t-1} + b_c)$$
$$= tanh(0.5) \approx 0.462$$

更新细胞状态：$C_t = f_t \cdot C_{t-1} = 0.645 \times 0 + 0.711 \times 0.462 \approx 0.329$

输出门：$W_o x_t = 0.2 \times 1 + 0.1 \times 2 = 0.4$

$$U_o h_{t-1} = 0$$
$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) = \sigma(0.5) \approx 0.622$$

隐藏状态：$tanh(C_t) = tanh(0.329) \approx 0.318$

$$h_t = o_t \cdot tanh(C_t) = 0.622 \times 0.318 = 0.198$$

隐藏状态：$\hat{y}_t = W_o x_t + b_y = 0.5 \times 0.198 + 0 = 0.099$

损失函数：

遗忘门：$L = \frac{1}{2}(y - \hat{y})^2 = \frac{1}{2}(10 - 0.099)^2 \approx 49.01$

反向传播：

输出层误差：$\delta_y = y - \hat{y} = 0.099 - 10 = -9.901$

输出层权重梯度：$\frac{\partial L}{\partial w_y} = \delta_y \cdot h_t = -0.099 \times 0.198 = -0.0196$

$$\frac{\partial L}{\partial b_y} = \delta_y = -9.901$$

误差回传到隐藏层状态：$\delta_h = \delta_y \cdot W_y = -9.901 \times 0.5 = -4.95$

输出门梯度：$\frac{\partial o_t}{\partial z} = o_t \cdot (1 - o_t) = 0.622 \times (1 - 0.622) = 0.235$

$$\delta_o = \delta_h \cdot tanh(C_t) \cdot \frac{\partial o_t}{\partial z} = -4.95 \times 0.318 \times 0.235 = -0.3699$$

长短期记忆网络(LSTM)

□ 模型擅长处理时序依赖，适用于信号分析、寿命预测等时间序列数据处理任务。

记忆状态C_t的梯度：

$h_t = o_t \cdot tanh(C_t)$

$\frac{\partial h_t}{\partial C_t} = o_t \cdot \left(1 - tanh^2(C_t)\right) = 0.622 \times (1 - 0.318^2) = 0.5591$

$\delta_{C_t} = \delta_h \cdot \frac{\partial h_t}{\partial C_t} = -4.95 \times 0.5591 = -2.77$

输入门i_t和候选记忆$\tilde{C}_t$梯度：

$C_t = i_t \cdot \tilde{C}_t + f_t \cdot C_{t-1}$

$\frac{\partial C_t}{\partial i_t} = \tilde{C}_t = 0.4621$

$\frac{\partial L}{\partial i_t} = \delta_{C_t} \cdot \tilde{C}_t = -2.77 \times 0.4621 = -1.28$

sigmoid：$\frac{\partial i_t}{\partial z_i} = i_t \cdot (1 - i_t) = 0.711 \times (1 - 0.711) = 0.205$

$\delta_{z_i} = -1.28 \times 0.205 = -0.2628$

候选记忆：$\frac{\partial C_t}{\partial \tilde{C}_t} = i_t = 0.711$

$\frac{\partial L}{\partial \tilde{C}_t} = \delta_{C_t} \cdot i_t = -2.77 \times 0.711 = -1.97$

$\frac{\partial \tilde{C}_t}{\partial z_{\tilde{C}}} = 1 - tanh^2(z_{\tilde{C}}) = 1 - tanh^2(0.5) = 0.7864$

$\delta_{z_{\tilde{C}}} = -1.97 \times 0.7864 = 1.549$

遗忘门f_t：$\frac{\partial C_t}{\partial f_t} = C_{t-1} = 0 \rightarrow \delta_{z_f} = 0$

参数更新：$\frac{\partial L}{\partial W_0} = \delta_{z_0} \cdot x = [-0.3688 \quad -0.7376]$

$\frac{\partial L}{\partial U_0} = \delta_{z_0} \cdot h_{t-1} = 0 \quad \frac{\partial L}{\partial b_0} = \delta_{z_0} = -0.3688$

$W_0^{(new)} = W_0 - \eta \cdot \frac{\partial L}{\partial W_0} = [0.2 \quad 0.1] + 0.01 \times [-0.3688 \quad -0.7376] = [0.2037 \quad 0.1074]$

$U_0^{(new)} = U_0 - 0 = [0.1]$

$b_0^{(new)} = 0 + 0.01 \times 0.3688 = 0.0037$

输入门权重更新：$\frac{\partial L}{\partial W_i} = \delta_{z_i} \cdot x = [-0.2628 \quad -0.5256]$

$W_i^{(new)} = [0.3 \quad 0.4] + 0.01 \times [0.2628 \quad 0.5256] \quad b_i^{(new)} = 0 + 0.01 \times 0.2628 = 0.0026$

候选记忆门权重更新：$\frac{\partial L}{\partial W_C} = \delta_{z_C} \cdot x = [-1.5499 \quad -3.0998]$

$W_C^{(new)} = [0.2 \quad 0.1] + 0.01 \times [1.5499 \quad 3.0998] \quad b_C^{(new)} = 0 + 0.01 \times 1.5499 = 0.0155$

遗忘门梯度为0：$\delta_{z_f} = 0$，所有的权重保持不变

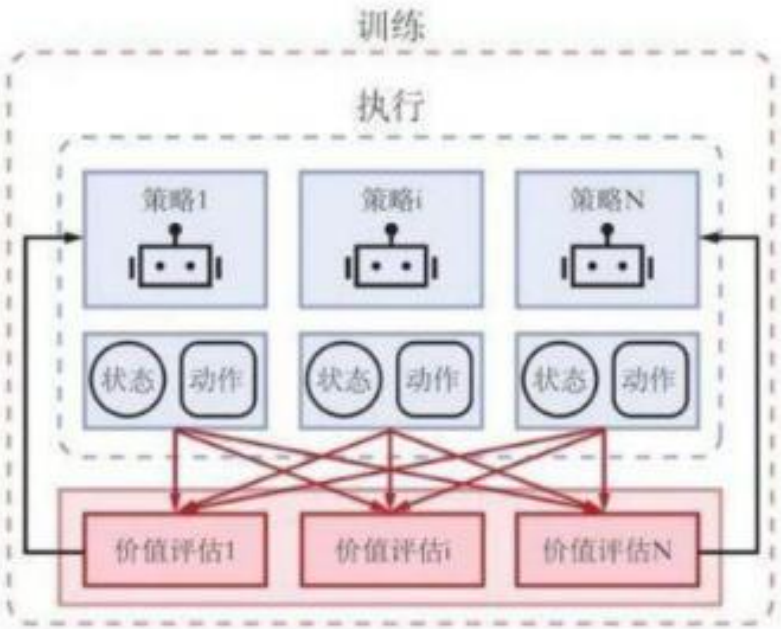
计算结果：

对上述过程重复100次，输出$\hat{y}$和MSE

迭代次数	输出$\hat{y}$	MSE
1	0.099	98.02
2	0.14	96.02
...	...	...
100	9.5	0.25

强化学习（RL）

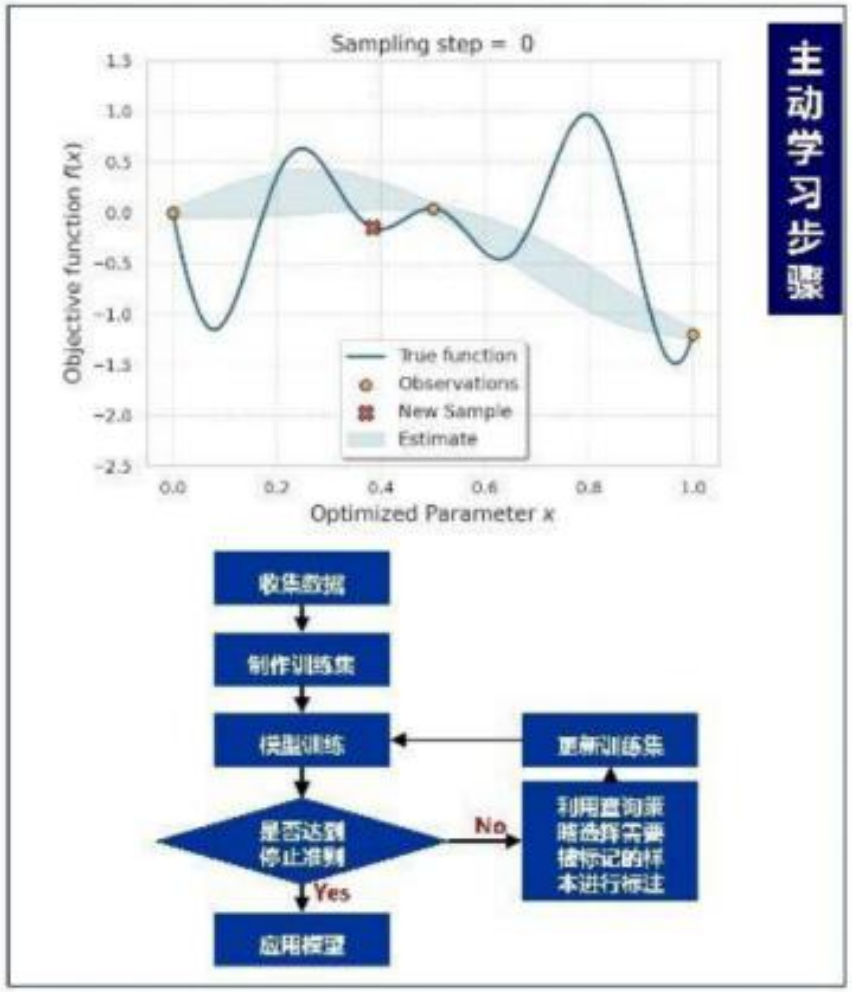
- 用于智能体在与环境不断交互的过程中，通过持续学习和优化决策策略，实现长期累积回报最大化或完成特定复杂任务目标的一类动态、反馈驱动的决策优化问题。



	强化学习	神经网络（深/浅）
目标函数	最大化长期累计回报	最小化监督损失（如 MSE）
决策单位	决策动作（从策略中采样或确定性选择）	对输入进行映射预测（如分类/回归）
学习对象	学习策略（policy）或价值函数	学习一个静态函数映射关系
反馈类型	动态奖励信号（reward）	静态标签（ground truth）
与环境的交互	与环境持续交互产生数据	无交互，单次前向预测
损失函数来源	来自时序差分误差或策略梯度	由监督信号直接定义
采样机制	主动选择动作以影响环境状态	被动接收输入样本

主动学习（AL）

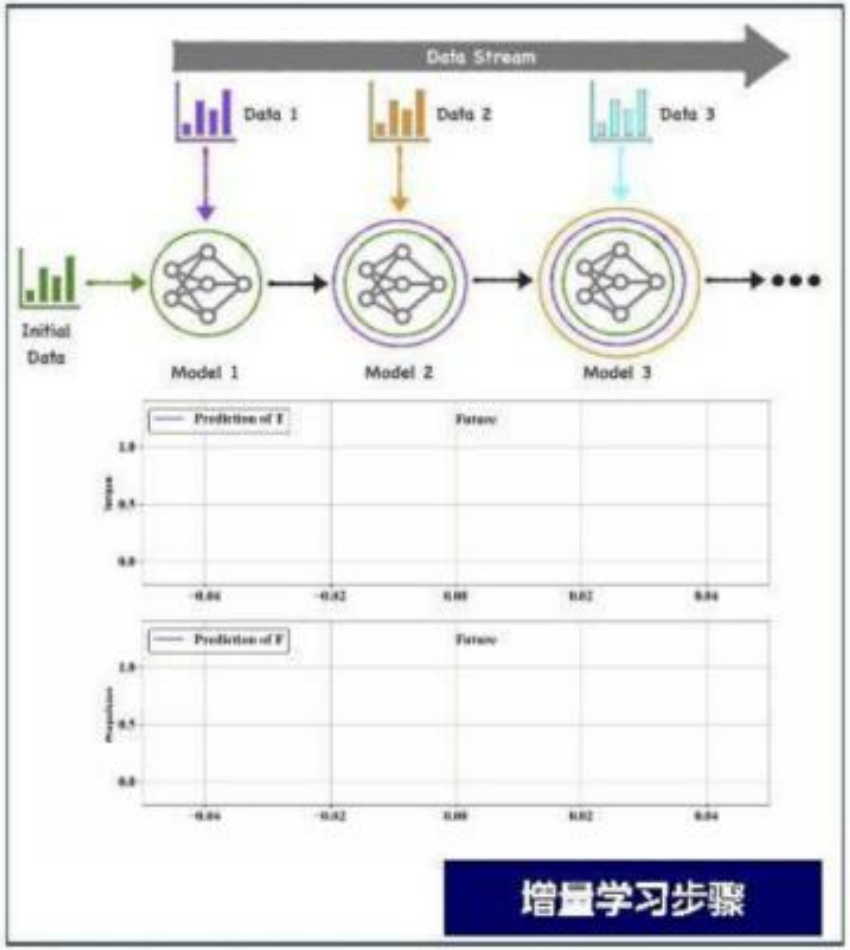
□ 智能选择高价值样本进行标注，适用于标注成本高的场景，显著提升数据利用效率。



	主动学习	神经网络（深/浅）
学习目标定位	学习“选择哪些样本进行学习”以最大化收益	学习“如何从已知样本中拟合输入输出映射”
是否主动选择样本	是（如不确定性采样、熵采样等）	否（训练集固定）
训练流程结构	迭代性地构建训练集，每轮训练后动态选样	一次性训练已有数据
样本利用效率目标	用尽可能少的样本达到尽可能好结果	倾向于用尽可能多的样本获得泛化性能
损失函数构造	在主动选择前使用损失或不确定度指标（如熵、Margin）评估样本	直接最小化训练集的均方误差/交叉熵等
是否需要人参与标注	是，主动学习需人提供选择样本的标签（专家在环）	否，训练数据预先准备好
模型结构依赖性	可以搭配任意模型（神经网络、SVM、树等）	是具体结构（感知器、CNN、LSTM等）
对数据池的假设	假设存在大量未标注数据池供选择	假设训练集已标注完备

增量学习（IL）

□ 模型支持在线更新，无需全量数据重训练，适用于数据流场景，动态适应新数据分布。



增量学习步骤

	增量学习	神经网络（深/浅）
目标函数	连续学习，保持性能与稳定性	一次性训练，最小化损失
决策单位	不断更新模型同时保留旧知识	批量训练后做预测
学习对象	流式数据或阶段性任务	静态数据上的单次学习
反馈类型	每次增量接收一批标签或少量反馈	统一训练集标签
与环境的交互	不断接收新数据，需适应分布漂移	一次性训练，无需适应
损失函数来源	与历史保持一致性的正则项	来自批量训练数据
采样机制	训练顺序重要（可致灾难遗忘）	随机采样批次训练

计算复杂度

- 衡量算法的计算效率，帮助评估模型在数据规模增大时的可扩展性，指导资源分配，优化模型设计（如层数、参数量），并在实际部署中平衡速度与精度。

模型	计算复杂度公式	说明
多项式拟合（最小二乘）	$O(nd^2 + d^3)$	n 为样本数，d为特征数
浅层神经网络	$O(Tn(dh + hk))$	输入维度d，隐藏神经元数h，输出维度k
深度学习神经网络	$O\left(Tn\sum_{l=1}^{L} h_{l-1}h_l\right)$	L层网络，第l层神经元数h_l，n为样本数，T是迭代步
卷积神经网络	$O\left(Tn\sum_{l=1}^{L} H_l' W_l' C_l K_l^2 M_l\right)$	$H \times W \times C$输出尺寸(高×宽×通道数)，卷积核尺寸K × K，数量M，L层I迭代步
图神经网络	$O(TnL(Eh + Nh^2))$	N为节点数，E为边数，节点特征维度d，隐层维度h，L层T迭代步
LSTM	$O(T_{iter}Tnh(d + h))$	输入维度d，隐藏状态维度h，n样本，T_{iter}迭代步



一、AI4M的背景意义

二、AI4M的基础知识

三、AI4M的研究进展

四、AI4M的案例展示

五、AI4M的瓶颈所在

六、AI4M的科学问题

七、AI4M的发展方向

八、思考与总结

AI的分类方式：以参数规模为例

□ AI模型可以根据模型的参数规模进行分类，以互联网模型和数据为例：

大模型

- **参数量：** 十亿~万亿级
- **灵活性：** 通用性强
- **训练成本：** 极高
- **推理速度：** 慢（需云端计算）
- **典型应用：** 多模态生成任务
  通用智能任务

小模型

- **参数量：** 百万~数亿级
- **灵活性：** 专用性强
- **训练成本：** 低
- **推理速度：** 快（可本地部署）
- **典型应用：** 垂直领域优化任务
  专用系统

微模型

- **参数量：** 百万以下
- **灵活性：** 高度定制化
- **训练成本：** 中等（需领域数据）
- **推理速度：** 取决于基础模型
- **典型应用：** 边缘侧实时控制
  低功耗嵌入式系统

Bilibili每天产生的数据量

bilibili

数据量：约7.8 PB
视频播放：51 TB
视频投稿：7.17 PB
互动数据：4.5 TB
用户行为日志：10.4 TB

智能汽车工厂每天产生的数据量



数据量：约2.0 TB
生产数据：750 GB(传感器数据、生产流数据)
供应链数据：200 GB
能源数据：50 GB
AI检测数据：1 TB

互联网平台与智能工厂的数据量级比约为 10^3~10^4 : 1，呈现显著的数量级差

AI4M：大模型、小模型、微模型

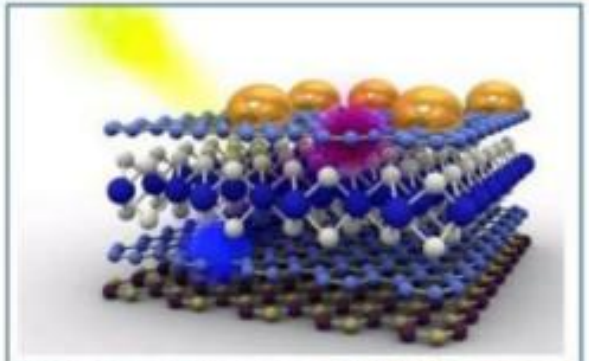
□ 根据AI模型的参数量级，可以将先进制造中的模型分为：大、小、微



模型类型	参数量级	应用场景	特点
大模型	>10M	智能工厂、多机协同...	泛化强、资源需求高
小模型	10k~10M	装备监测、数字孪生...	响应快、适配性好
微模型	<10k	优化设计、性能分析...	极低延迟、轻量部署

AI4M：材料、设计、制造、运维

工程材料、设计优化、加工装配、控制运维是重大装备先进制造的四个主要阶段

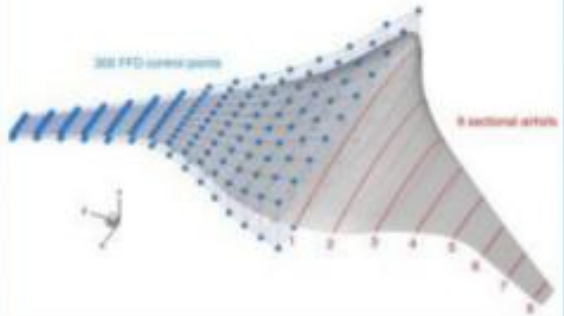




纳米材料/复合材料

材料





工业设计/优化设计

设计





精密制造/3D打印

制造





设备监控/故障诊断

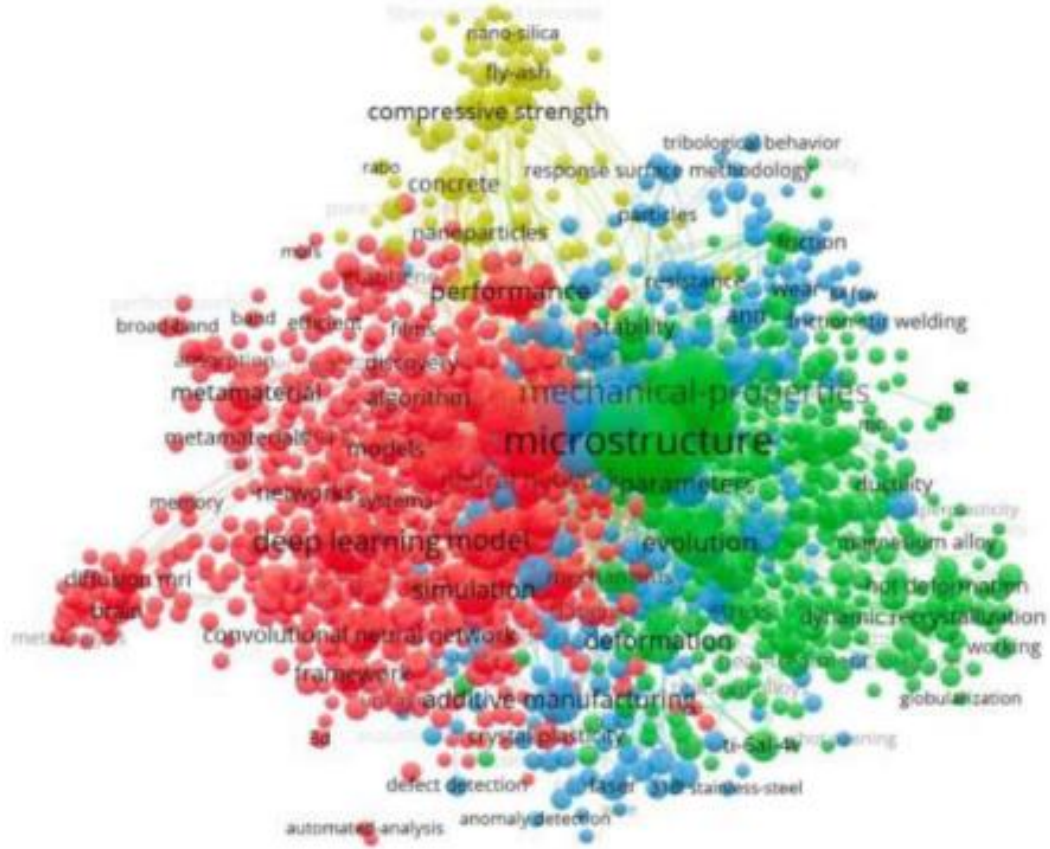
运维

AI4M统计：工程材料

□ 对“AI+工程材料”相关关键词进行检索，并绘制统计图和关键词共现图谱



检索式： TS=("artificial intelligence" OR "machine learning" OR "deep learning" OR "neural network" OR "data-driven") AND TS=("material design" OR "composite material" OR "material discovery" OR "microstructure"OR"metamaterial"OR"material property")



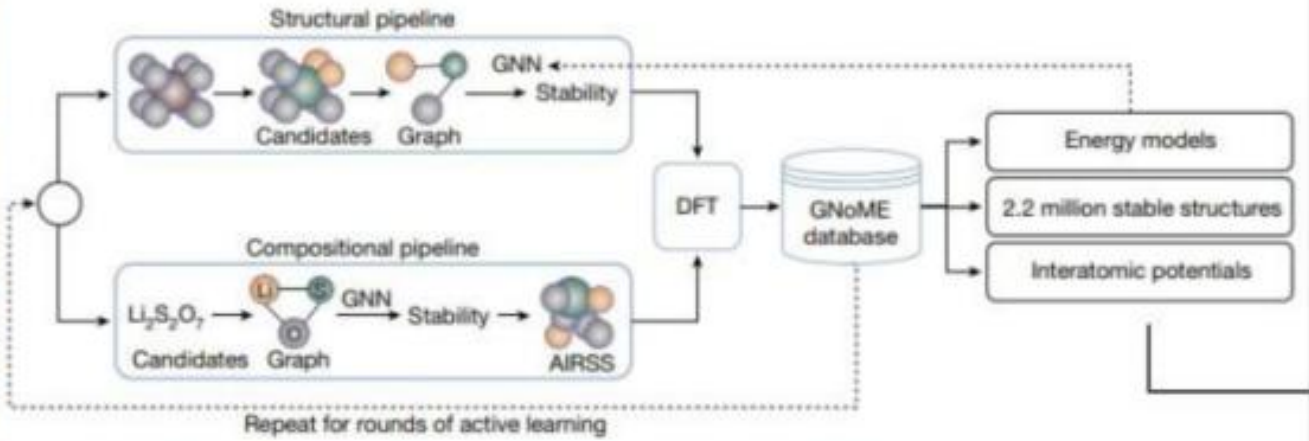
关键词共现图谱

AI4M案例：工程材料

- **大模型应用于新材料发现：DeepMind团队提出的GNOME图神经网络，快速发现220万个新的材料晶体结构，将材料发现的效率提高了一个数量级。**

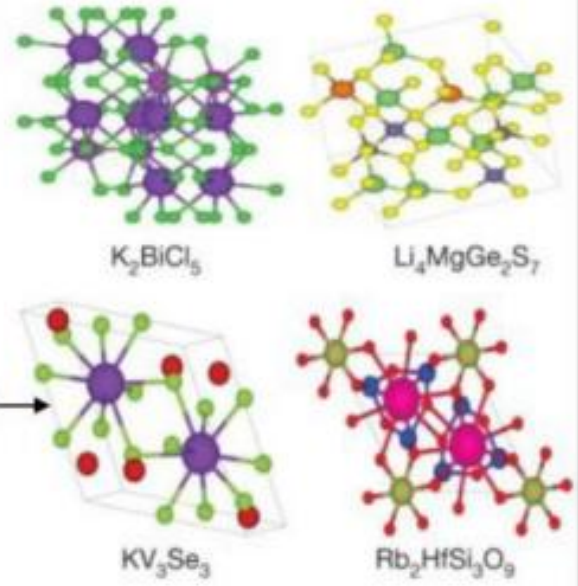






模型：GNOME图神经网络　参数量：15M
效果：将材料发现的效率提高了一个数量级

大规模图网络



模型预测的新材料结构

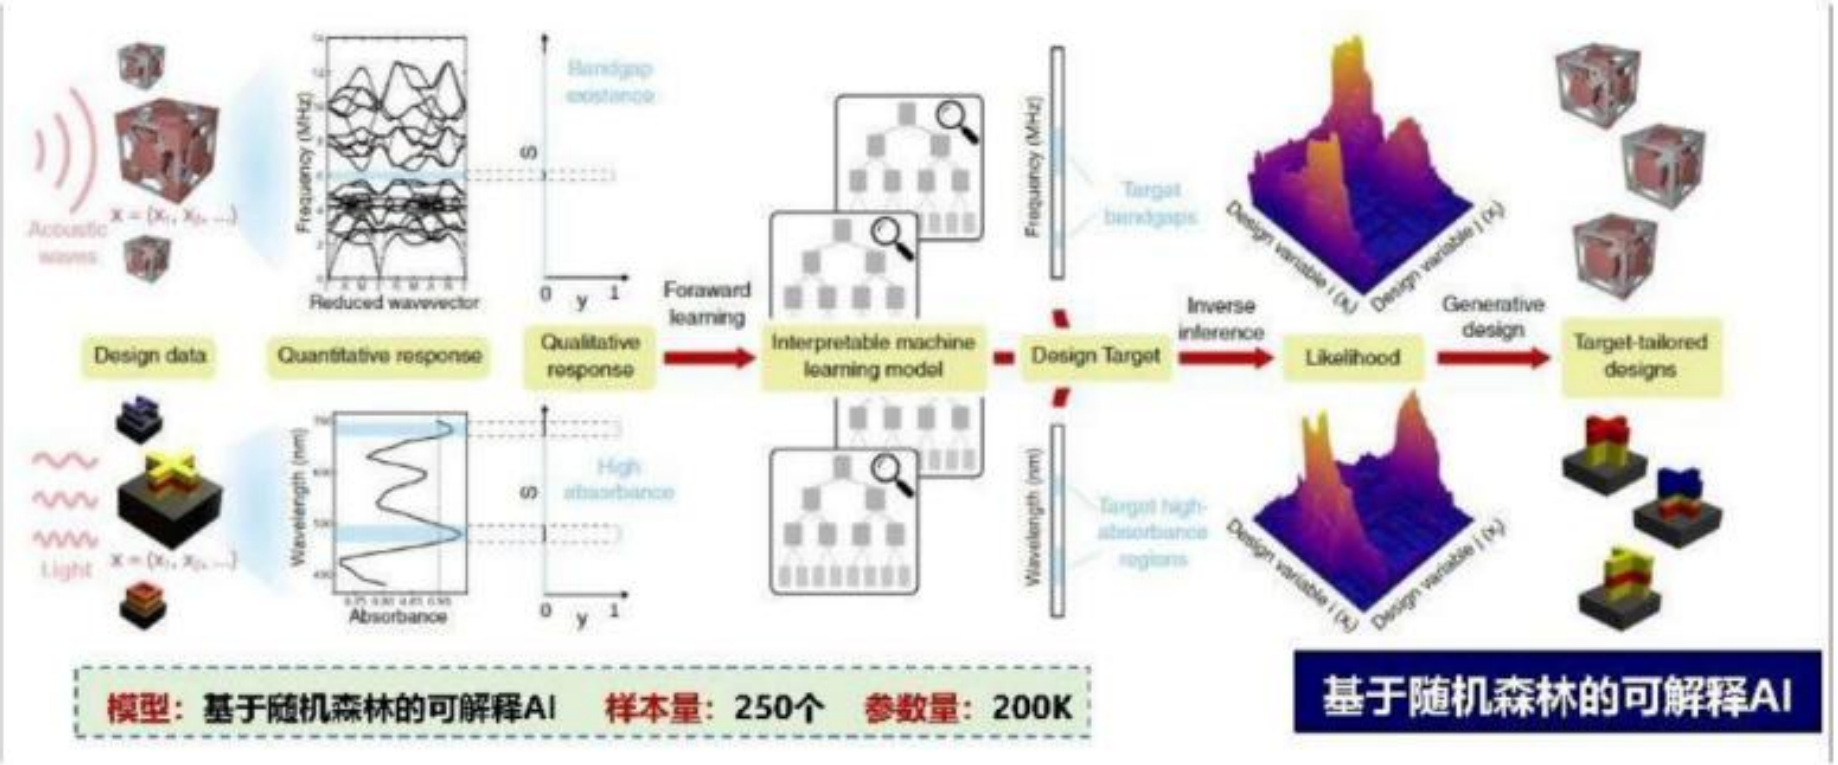
Merchant A, et al. Scaling deep learning for materials discovery. **Nature**,2023, 624(7990): 80-85.

AI4M案例：工程材料

□ **小模型应用于超材料设计：通过可解释的随机森林微模型，实现超材料的快速设计，发现更多可行解和可行结构，大幅缩短工程材料设计的研发周期。**



美国双院院士
Wei Chen



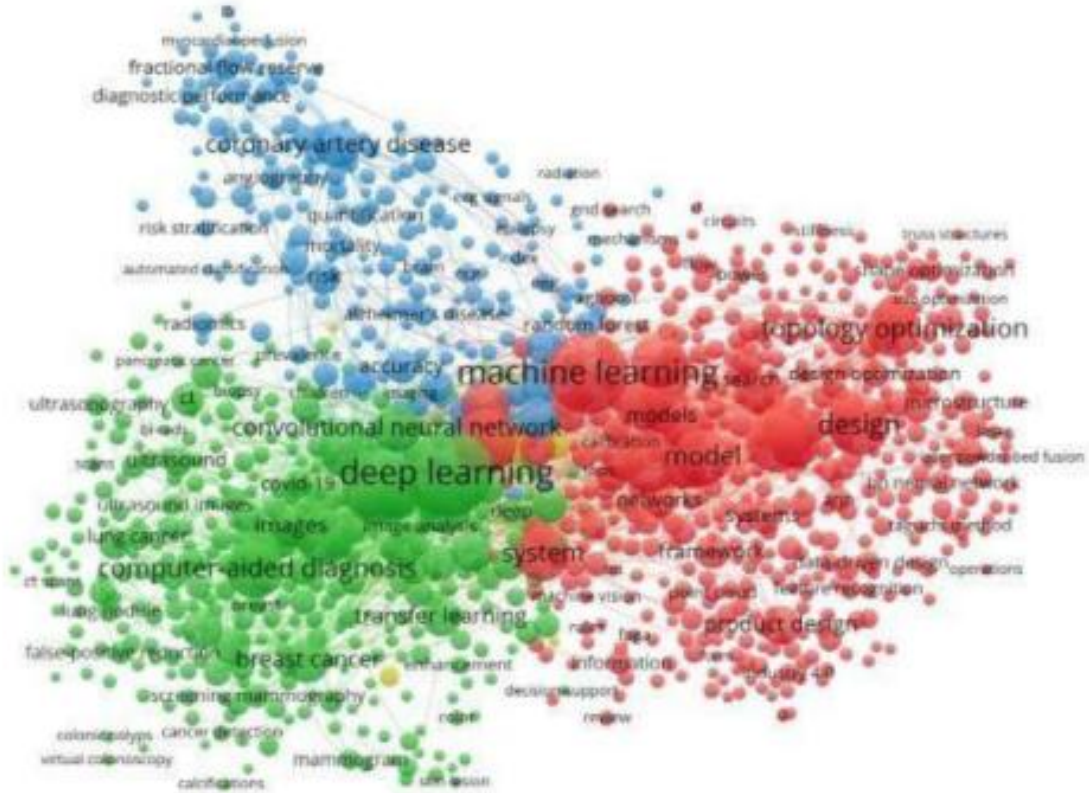
Chen W, et al. Generative inverse design of metamaterials with functional responses by interpretable learning. Advanced Intelligent Systems,2024: 2400611.

AI4M统计：设计优化

□ 对“AI+设计优化”相关关键词进行检索，并绘制统计图和网络共现图谱



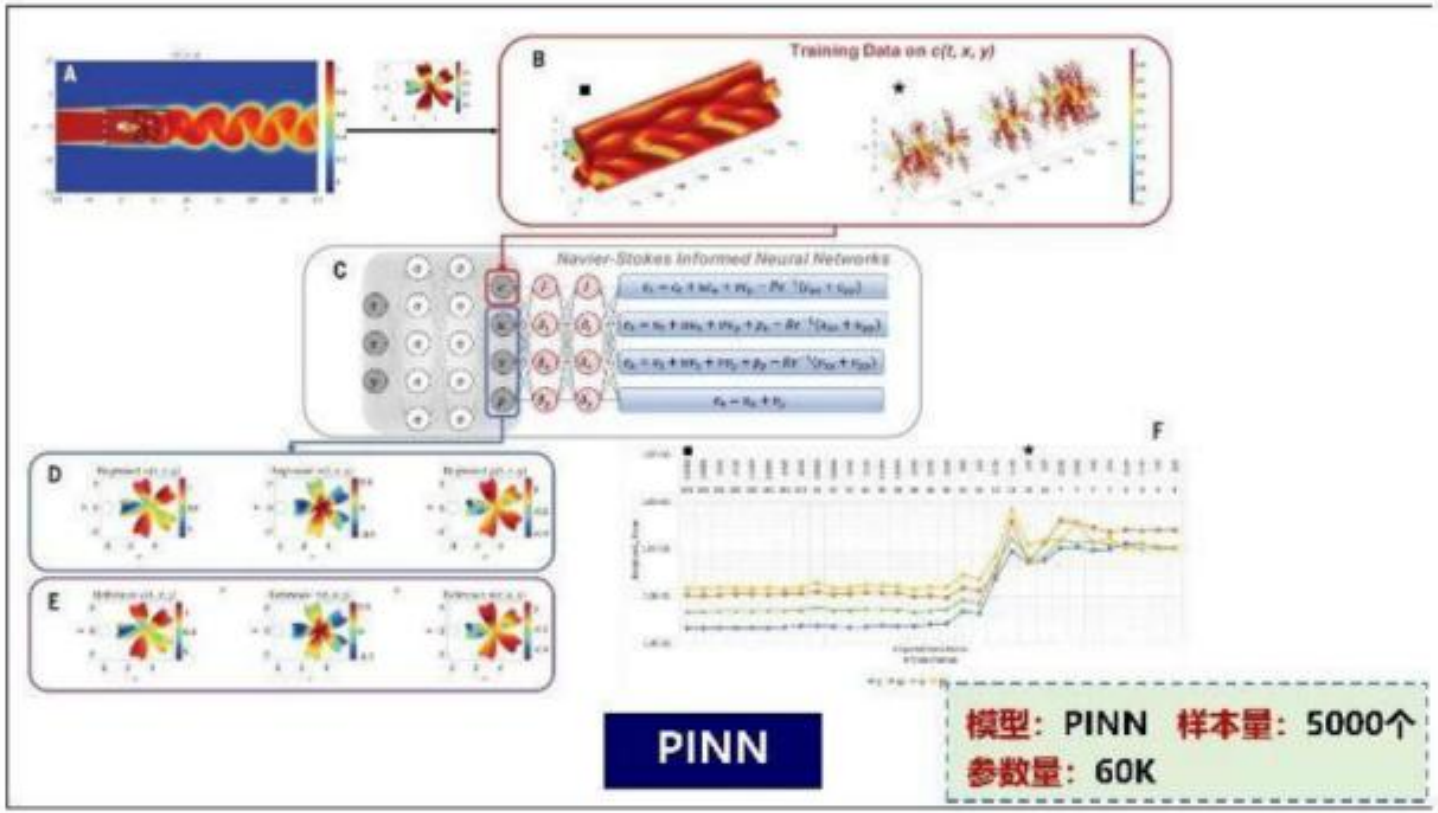
检索式： TS=("artificial intelligence" OR "machine learning" OR "deep learning" OR "neural network"OR"data-driven") AND TS=("mechanical design" OR "topology optimization" OR "CAD" OR "structural optimization"OR"parameter optimization"OR"product design")



关键词共现图谱

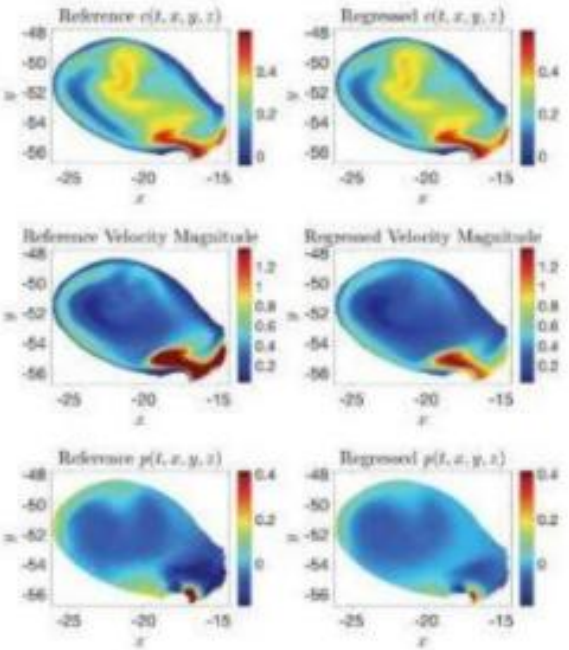
AI4M案例：设计优化

□ **小模型应用于流场重构：结合流场可视化数据和Navier-Stokes方程，通过PINN小模型从5000个仿真云图中直接推断出流体速度场和压力场。**



PINN

模型：PINN 样本量：5000个
参数量：60K

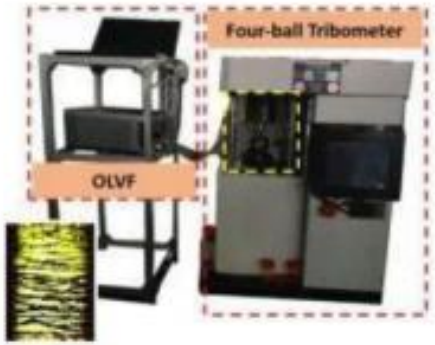


预测结果

Raissi M, et al. Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations. **Science**,2020, 367(6481): 1026-1030.

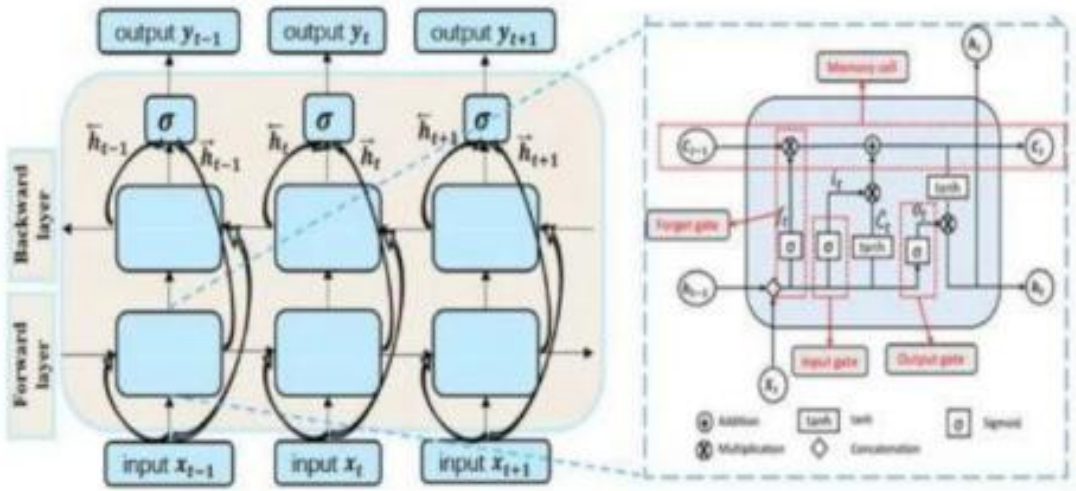
AI4M案例：设计优化

□ 小模型用于摩擦与润滑预测：针对在线铁谱监测磨损存在延迟、预测精度低问题，基于CSTS数据集构建方法及Bi-LSTM模型，实现摩擦系数及IPCA预测。



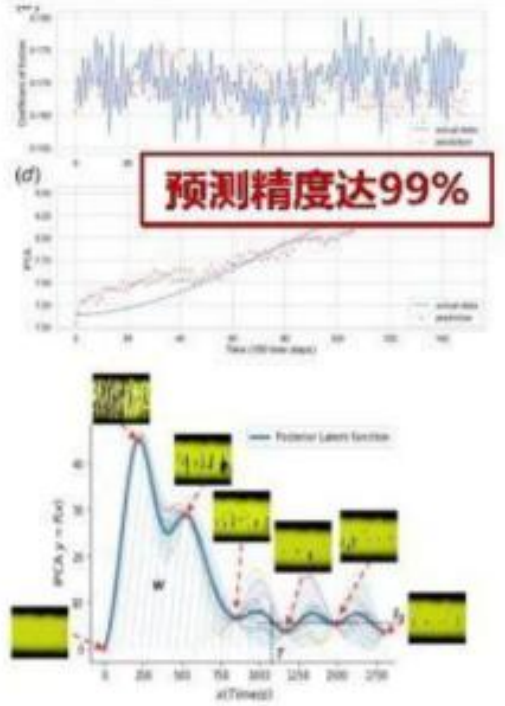


数据采集及数据集构建



模型：Bi-LSTM；　参数量：2M
算法效果：较传统方法（如MLP、Dilated CNN等）的均方误差降低50%以上，有效捕捉磨合期的高波动磨损特征

训练深度学习模型Bi-LSTM

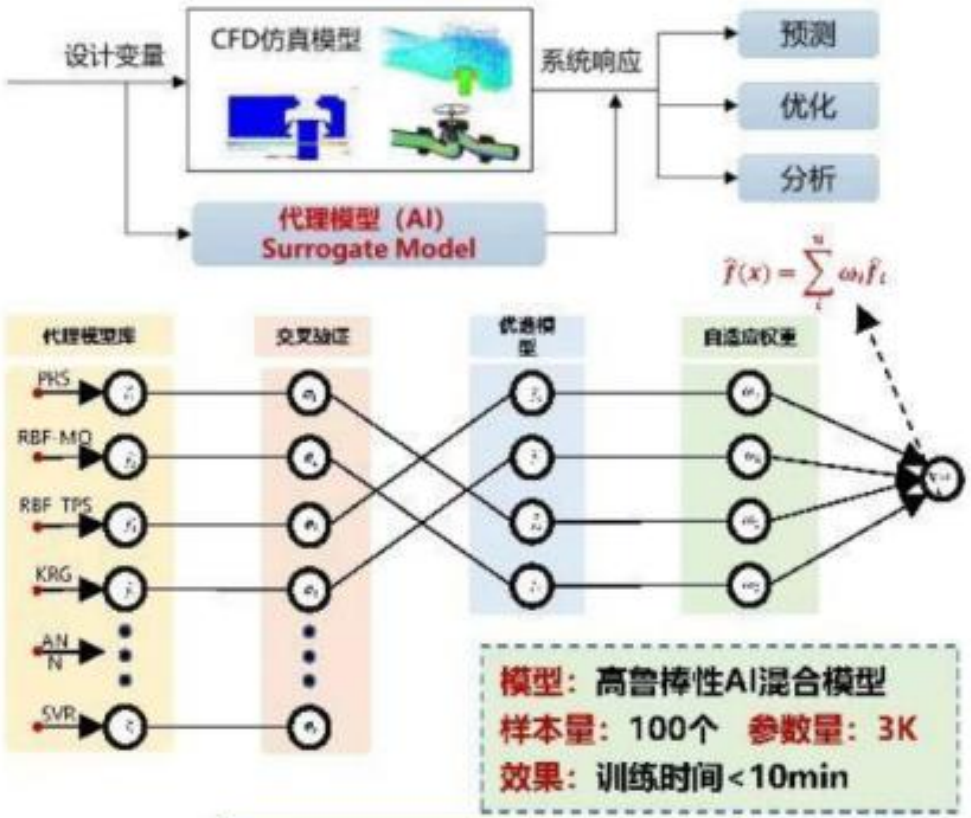


摩擦系数及IPCA实时预测

Zhang Zhinan*, et al. Short-Term Cross-Sectional Time-Series Wear Prediction by Deep Learning Approaches. Journal of Computing and Information Science in Engineering, 2022, 23(021007).

AI4M案例：设计优化

□ **微模型用于核电阀门的性能预测：** 基于逐点概率分布的高鲁棒性AI混合模型技术，对核电阀门关键性能预测精度＞95%，可以替代初始CFD模型分析。



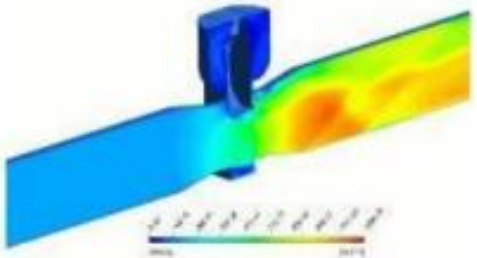
高鲁棒性AI混合模型





阀门优化设计





阀门动态结果